LECTURE 02

让上下文服务真实目标

02

从可验证规格、审美选择，到长程探索与研究判断

28 节 · 44 幅配图 · 5 道自测　回看课堂 ↗

完整阅读20块导出转写，覆盖00:00.15–1:38:25.12；未逐秒听审原音频。

讲义采用2026-10-02取得的官方网页版本，可能包含课堂后增补；口述、当前讲义补充和整理者解释分开标明。

讲义图源为本次生成的网页截图汇编PDF，不是官方发布PDF，也不是对应时间的视频截图。另补10张按重点采样的现场完整视频帧，保留上下文自查、代码阅读、主页交互、文学约束与论文阅读；未逐步复核全部屏幕操作。

模型名称、能力判断、训练机制及社会预测保留课堂语境，不作当前产品能力保证。

已做390px窄屏和900px桌面浏览器模拟，检查图片加载、目录、放大和关闭；未做真实手机设备测试。

阅读导引

先把握本课主线

01 提示词工程应检查模型看到的**整套上下文**；代码、历史与工具结果都会影响后续选择。

02 把模糊意图变成明确规格与**可验证的完成条件**，同时检查验收器是否代表**真实目标**。

03 复杂任务要保存**中间结果**、检查并修补；开放问题还需要设计**搜索覆盖**，而不只是延长一次回答。

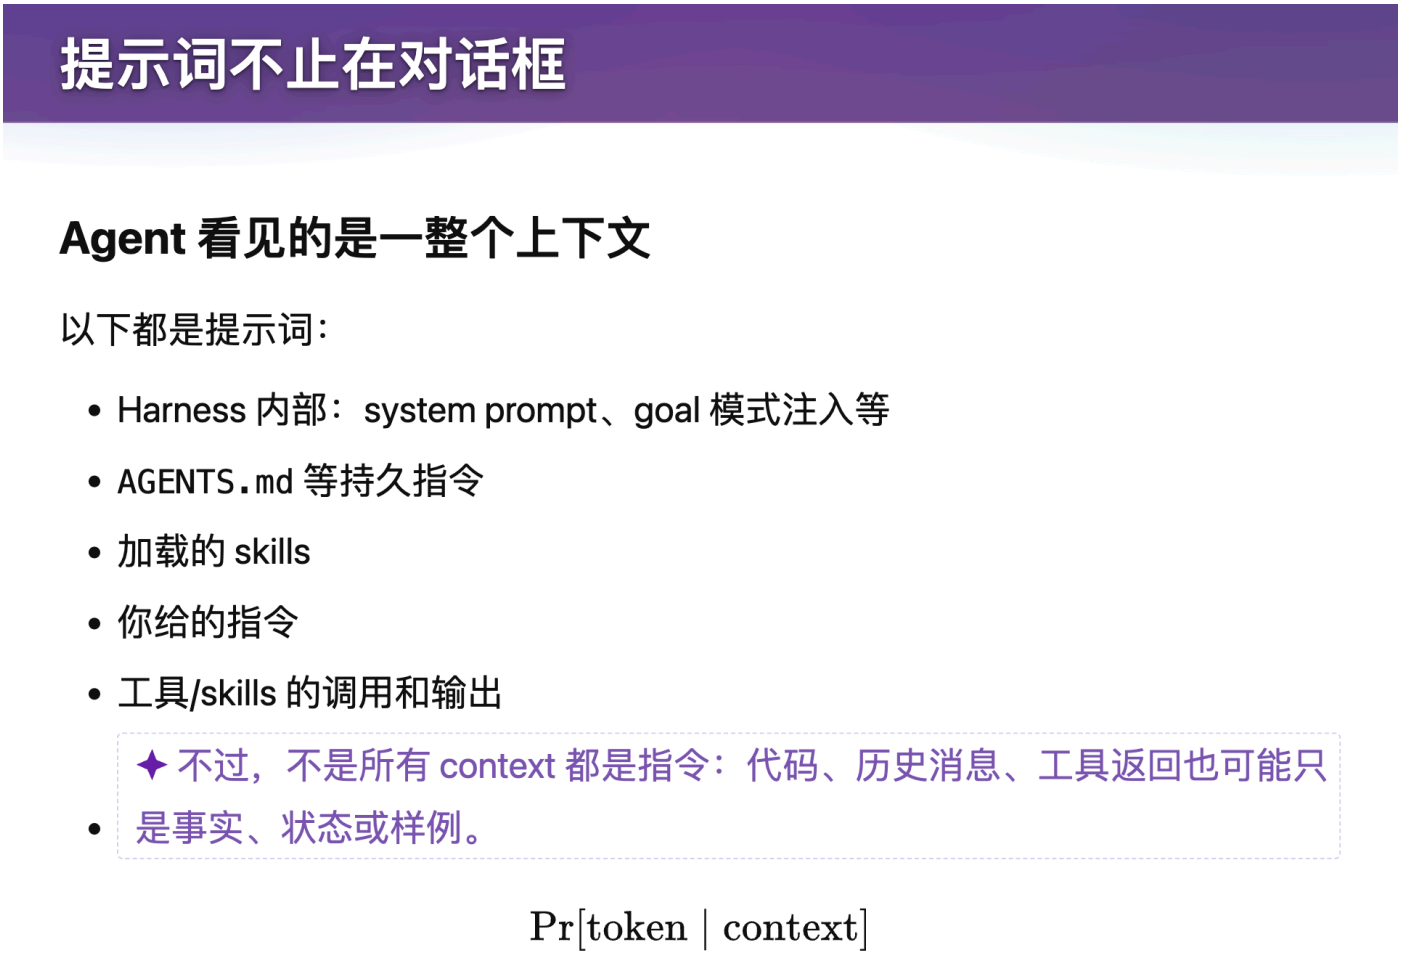
04 人类的产品、**领域**与审美知识决定该约束什么；论文审查和**研究探索**尤其不能被现成故事带走。

第 01 节 00:00:00—00:04:54 · 课堂时间

提示词的范围：Agent 每次决策看见整个上下文

> **关键判断 · 整理者提炼**
> 提示词优化要检查模型实际看到的全部上下文，并用行为确认它如何影响执行。

本课把提示词从“输入框里的一句话”扩展到模型实际看到的**上下文**。除了用户消息，还包括**系统提示**、全局和项目级 AGENTS.md、按任务加载的 Skill、工具定义、工具调用与返回、历史对话和环境信息。优化提示词，因而要检查这些内容如何一起影响执行。



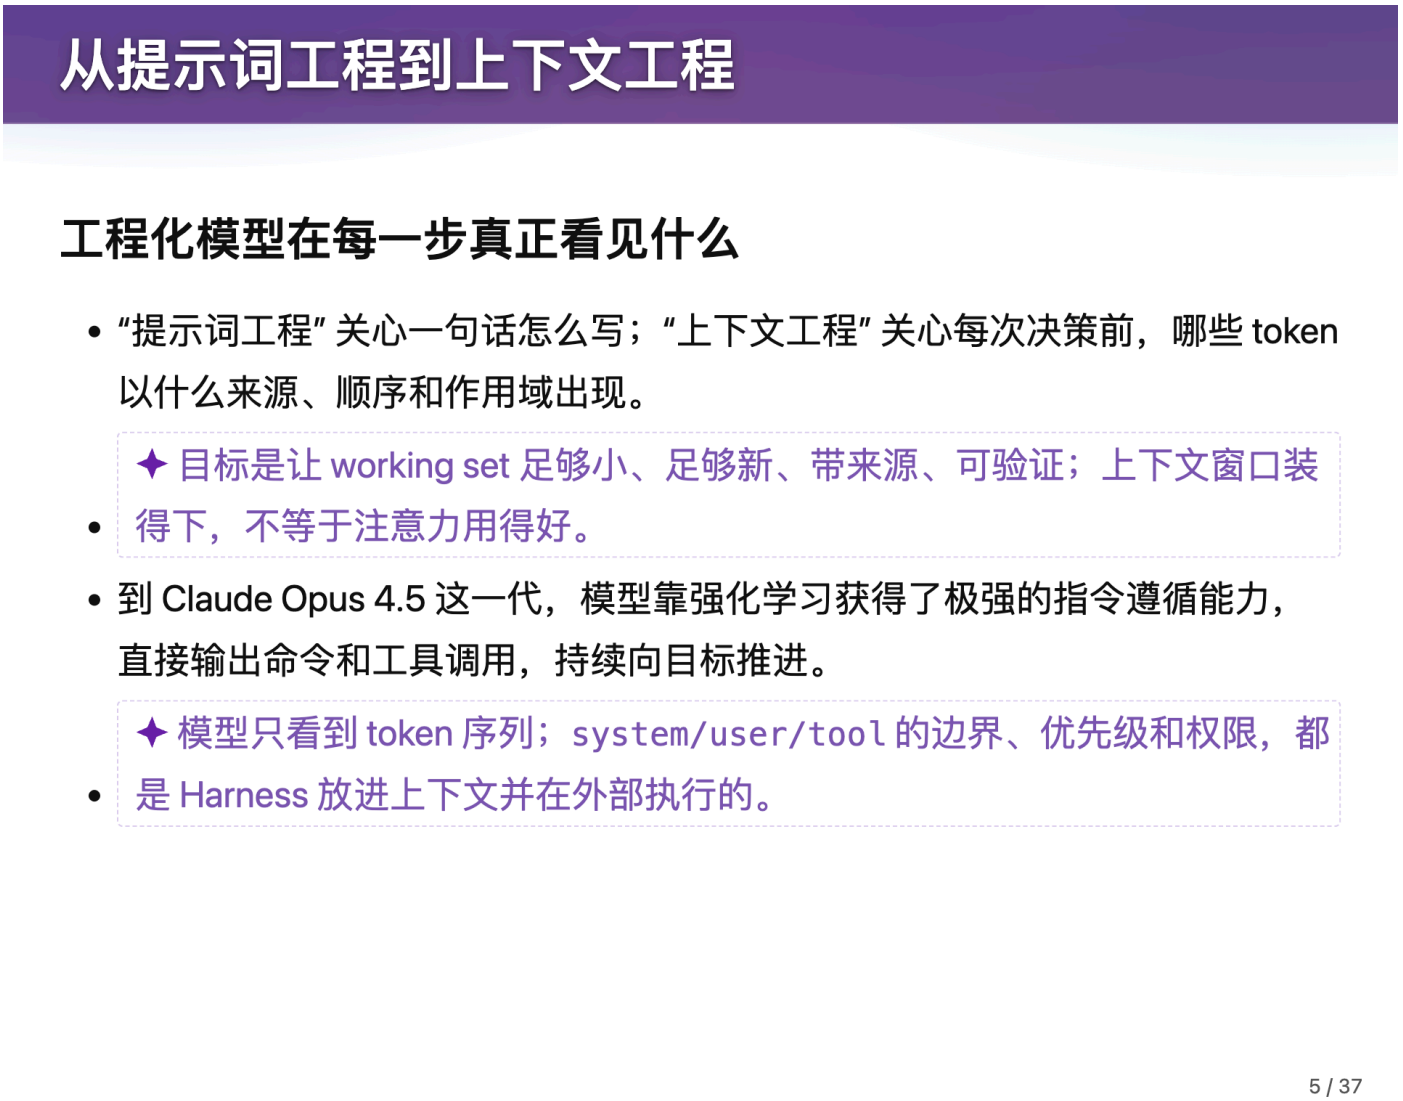
资料图 · 第 4 页 当前官方网页讲义第4页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 4 · 原始讲义 · 相关讲解 00:00:00（不是同秒视频截图） · 当前官方网页讲义第4页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

讲师用早年请 ChatGPT 解释 inline assembly 的经历说明变化：即使示例做了非典型改动，模型仍能给出有帮助但并不完美的解释。重点是新的交互方式降低了理解陌生代码的门槛，不是证明模型永远正确。

模型逐步预测下一个 token；在 Agent 中，输出可以继续形成说明、代码或工具调用。较长**上下文**能够承载复杂约束，但“装得下”与“**始终遵守**”不同。课堂提到用固定句尾词是否消失观察指令遗失的民间办法，只能作为异常线索，不能据此确定是截断、压缩还是注意力失效。

> **整理者说明**
> 讲义补充：不是所有 context 都是指令，代码、历史和工具结果也可能只是数据或证据。模型自述不是内部状态的可信转储，需要用**可见行为**交叉核对。



5 / 37

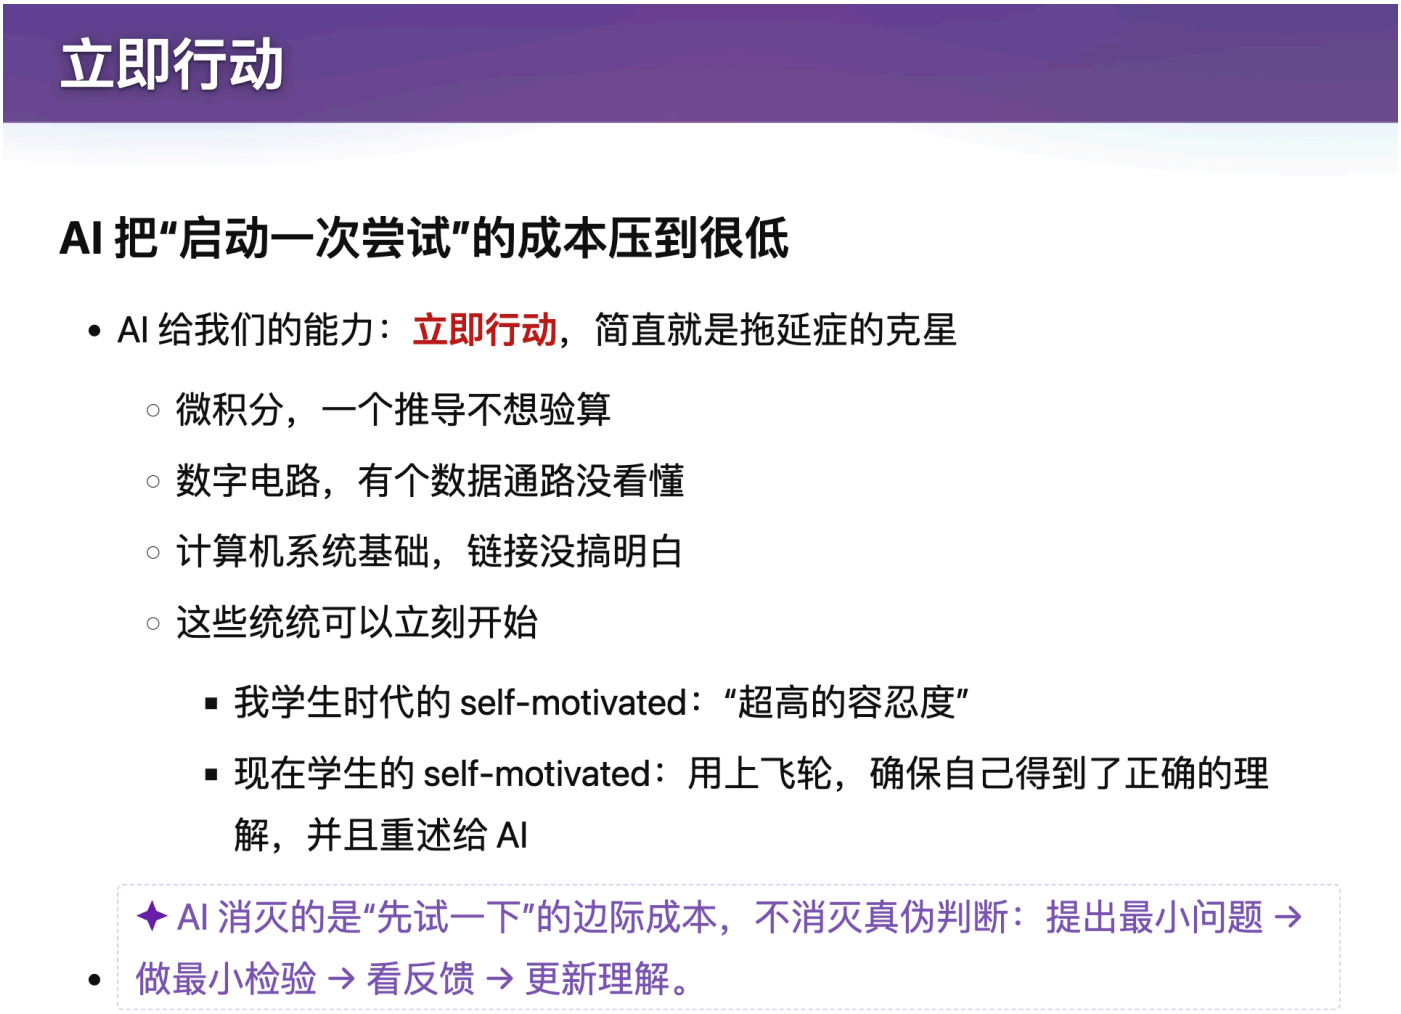
资料图 · 第 5 页 当前官方网页讲义第5页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 5 · 原始讲义 · 相关讲解 00:00:00（不是同秒视频截图） · 当前官方网页讲义第5页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

立即动手：让 Agent 解释工作环境

> **关键判断 · 整理者提炼**
> 将上下文结构变成可查文件与可观察行为，比只记住定义更能建立理解。

AI 降低的是**启动一次尝试**的成本。遇到不会的推导、数字电路或链接机制，可以立刻提出一个小问题，再追问，而不必等有空请教别人。



资料图 · 第 6 页 当前官方网页讲义第6页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

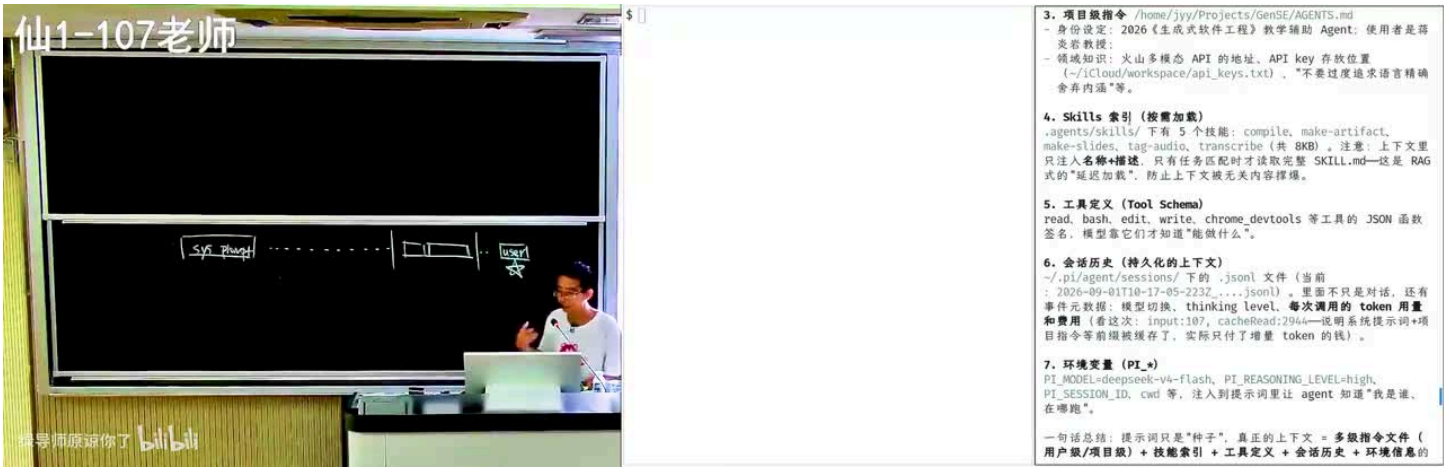
官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 6 · 原始讲义 · 相关讲解 00:04:54（不是同秒视频截图） · 当前官方网页讲义第6页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

现场让 Agent 分析它的**上下文来源**。它报告了系统约束、用户自写的中文回答与 recap 要求、项目级指令、Skill 索引、工具定义以及每轮环境信息。讲师强调 Skill 描述与完整正文不同，通常先看到**简短描述**，匹配任务才读取细节。



视频原帧 07:30现场结果上半部分：模型说明用户级与项目级AGENTS.md、Skill索引等来源。它是课堂工具的自述与屏幕证据，不是本笔记对模型内部状态的独立转储。

视频原帧 00:07:30 · 07:30现场结果上半部分：模型说明用户级与项目级AGENTS.md、Skill索引等来源。它是课堂工具的自述与屏幕证据，不是本笔记对模型内部状态的独立转储。

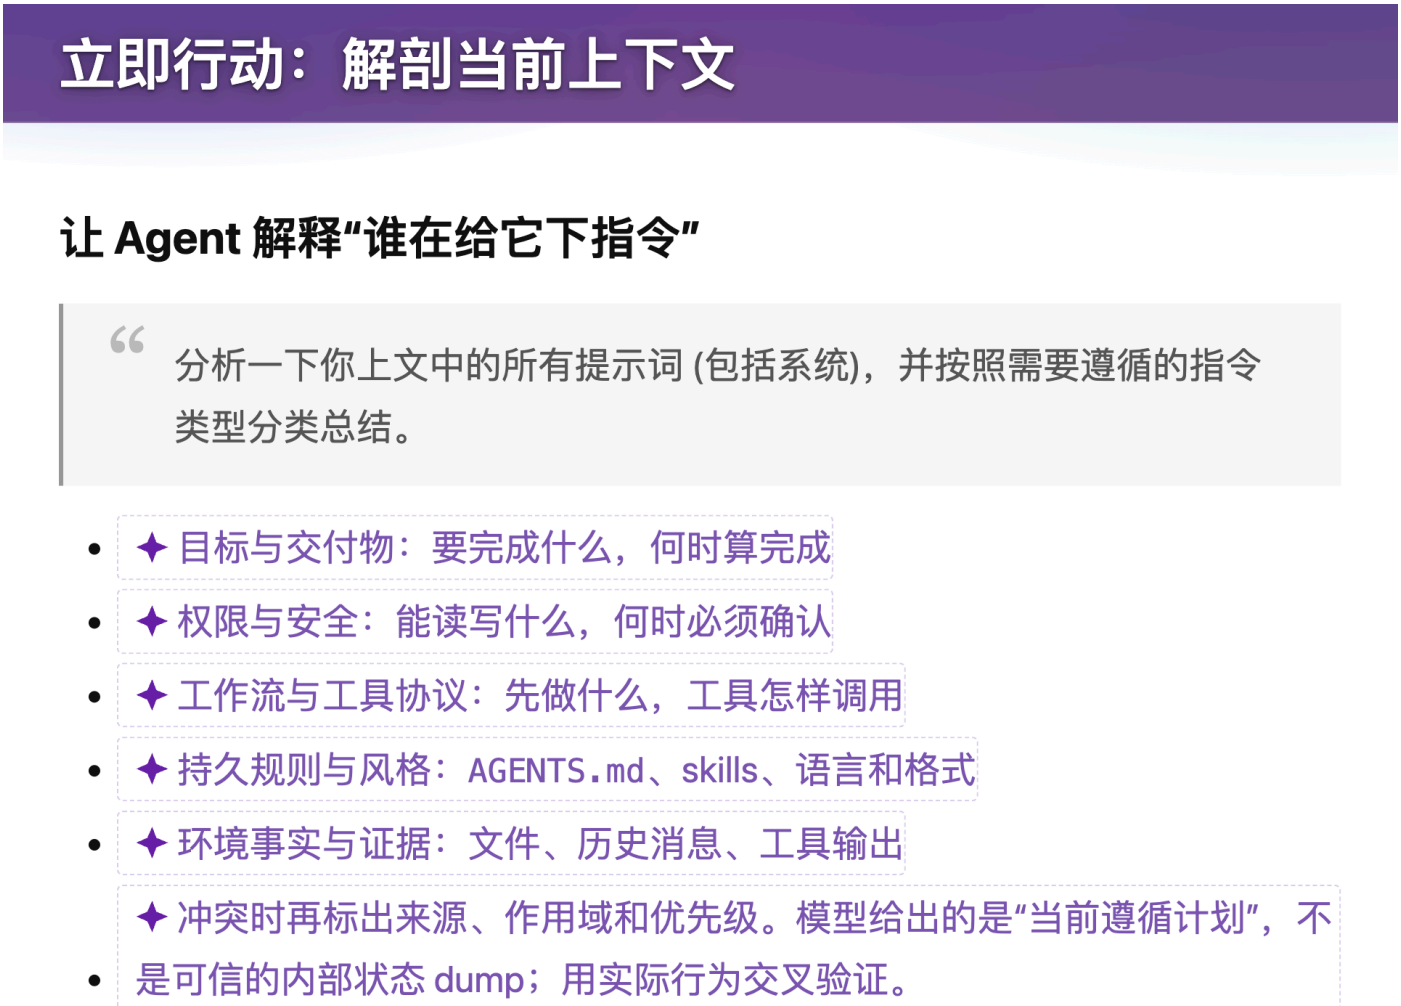


视频原帧 08:10现场结果下半部分：Skill索引、工具定义、会话历史和环境变量。两帧共同保存这次上下文自查的主要结果。

视频原帧 00:08:10 · 08:10现场结果下半部分：Skill索引、工具定义、会话历史和环境变量。两帧共同保存这次上下文自查的主要结果。

这一演示的学习方式是把抽象概念变成**可检查对象**：既然说上下文不止用户提示，就去查当前系统如何组织它，再沿文件和行为核实，而不是停在一个定义上。

> **整理者说明**
>
> 课堂对 Skill 加载/移出上下文的说明针对演示环境；不同 Agent 的持久化和压缩机制可能不同，不当作全部产品的通用实现。受保护的系统指令也不因“学习”而可以提取。



资料图 · 第 8 页 当前官方网页讲义第8页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 8 · 原始讲义 · 相关讲解 00:04:54（不是同秒视频截图） · 当前官方网页讲义第8页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

第 03 节

00:09:31—00:11:12 · 课堂时间

费曼学习法：把解释权交回自己

> **关键判断 · 整理者提炼**
>
> 先独立组织解释，再利用追问发现跳步与矛盾，才能检验是否真正理解。

第一轮把 AI 当老师，用追问补齐不懂的地方；第二轮**自己当老师**，让 AI 当学生，指出解释中的**跳步**、矛盾和漏项。能读懂现成答案，不代表能独立组织一个解释。



资料图 · 第 7 页 当前官方网页讲义第7页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 7 · 原始讲义 · 相关讲解 00:09:31（不是同秒视频截图） · 当前官方网页讲义第7页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

操作上可以先**合上资料**，用自己的话讲清概念，再让 AI 追问。卡住时回到证据修正，随后重新讲一遍。这样形成理解、表达、反馈和**重述**的循环。

> 案例回扣 可用课堂方法自测：我来解释 Agent 的上下文有哪些来源；请作为听众指出我把“指令”和“事实”混为一谈的地方，不替我直接写完整答案。此句为整理者依据课堂方法改写。

第 04 节

00:11:12—00:15:29 · 课堂时间

从一个小疑问读源码：命令为什么有时需要审批

> **关键判断 · 整理者提炼**
>
> 审批机制的判断需要回到实际实现，操作边界还取决于环境、参数与执行语义。

讲师留意到 Agent 执行 shell 时并非每条命令都询问用户，于是把问题变成**源码阅读任务**：风险判断来自静态分析、模型评级，还是其他机制？让 Agent 直接读取相关实现。

沙箱与审批带来取舍：限制降低误操作风险，却可能使无人值守任务停在确认处。课堂以去吃饭后发现任务早已等待确认为例，说明工作流设计需要考虑这种停顿。

单看命令名称不能推出安全性。讲师用“ls 在特殊环境中可能被改成别的行为”提醒，**环境、参数和执行语义**都可能影响结果。

> **整理者说明**
> 讲义补充：模型提出操作，**Harness**、沙箱和审批策略共同执行边界；当前官方讲义还补充了命令参数相关漏洞案例。这里没有重新审计当前 Codex 源码，不能把课堂演示推定为所有版本实现。



资料图 · 第 9 页 当前官方网页讲义第9页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 9 · 原始讲义 · 相关讲解 00:11:12（不是同秒视频截图） · 当前官方网页讲义第9页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

配置工具并验证解释：代码阅读不是盲信回答

> **关键判断 · 整理者提炼**
> 模型对实现的说明需要设计文档、源码和行为实验共同印证。

Agent 检索代码时可以借助**语言服务**和 IDE 信息。讲师借 VS Code 的红线说明：配置 **include path** 等环境，才能得到跳转、符号重命名和其他完整功能；“受控环境能编译”不等于日常开发配置已经正确。

现场回答提到了静态分流与模型风险评估。讲师并未把一次输出当最终事实，而是提出检查 prompt、观察行为变化等进一步证据。核心是让解释能落到代码与**实验结果**。

> 案例回扣　现场屏幕在约18:00显示对codex-rs/core/src/guardian/prompt.rs的读取，以及approval_request.rs中的guardian_approval_request_to_json、CommandApprovalAction等检索。该细节说明回答至少进入了实际源码，而不是仅凭通用知识解释；本次没有重新运行或审计当时仓库。



视频原帧　18:00代码阅读过程：Agent读取guardian/prompt.rs并在approval_request.rs检索风险评估相关结构。画面保存了检索路径与命令，不能单凭这一帧证明其后解释完全正确。

视频原帧 00:18:00 · 18:00代码阅读过程：Agent读取guardian/prompt.rs并在approval_request.rs检索风险评估相关结构。画面保存了检索路径与命令，不能单凭这一帧证明其后解释完全正确。

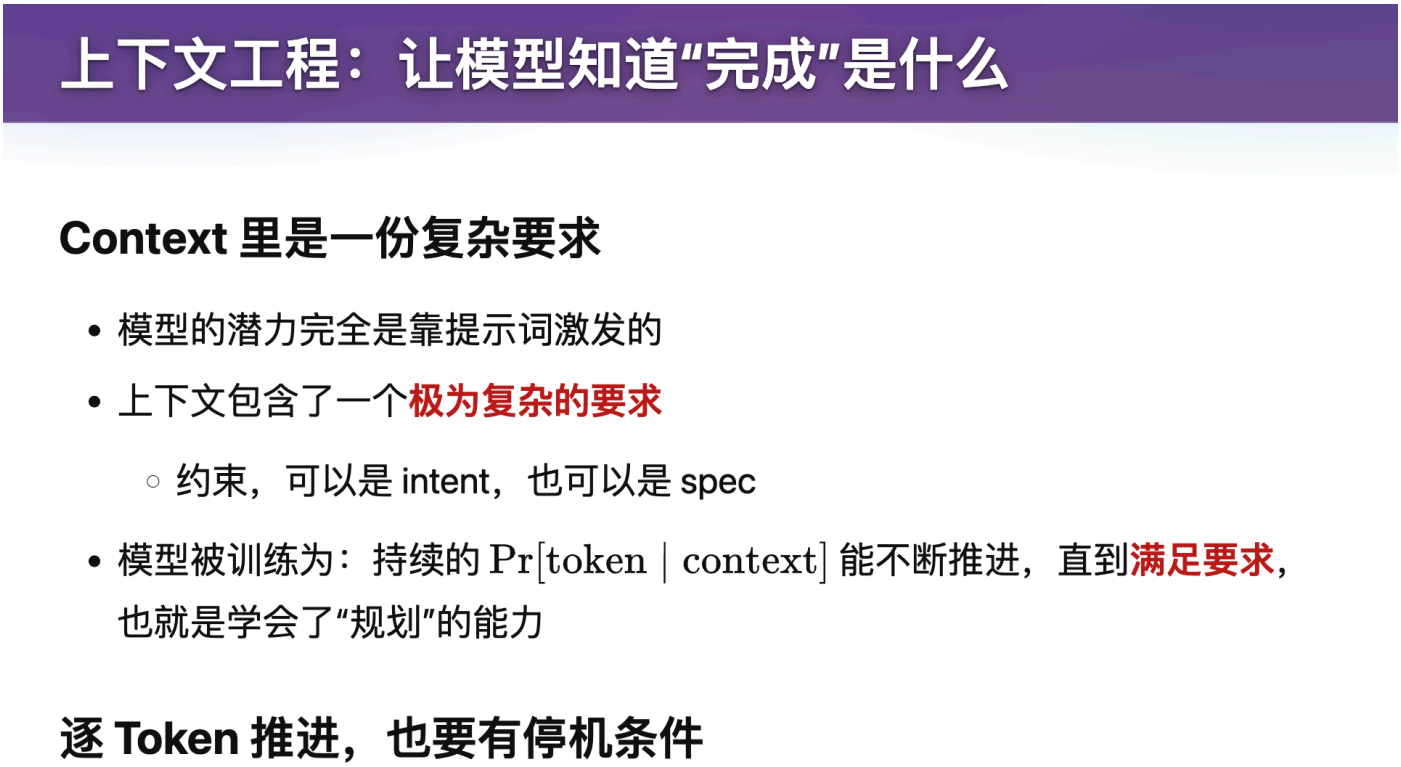
读实现时应同时看**设计理由**、规格文档和**具体代码**，三者相互印证。只听模型描述一个看似合理的机制，仍可能被错误解释带走。

第 06 节　　00:18:54—00:22:34 · 课堂时间

Intent → Spec → Implementation：把完成条件写出来

> **关键判断 · 整理者提炼**
> 把模糊意图变成规格和可执行验收，能提供纠错信号，但验收器本身仍须代表真实目标。

人的**意图**、**系统规格**和最终实现之间存在空隙。只说“做一个国民级应用”，模型需要自行补全语言、架构和许多产品选择；即使它认为任务完成，也可能离你的真实目标很远。



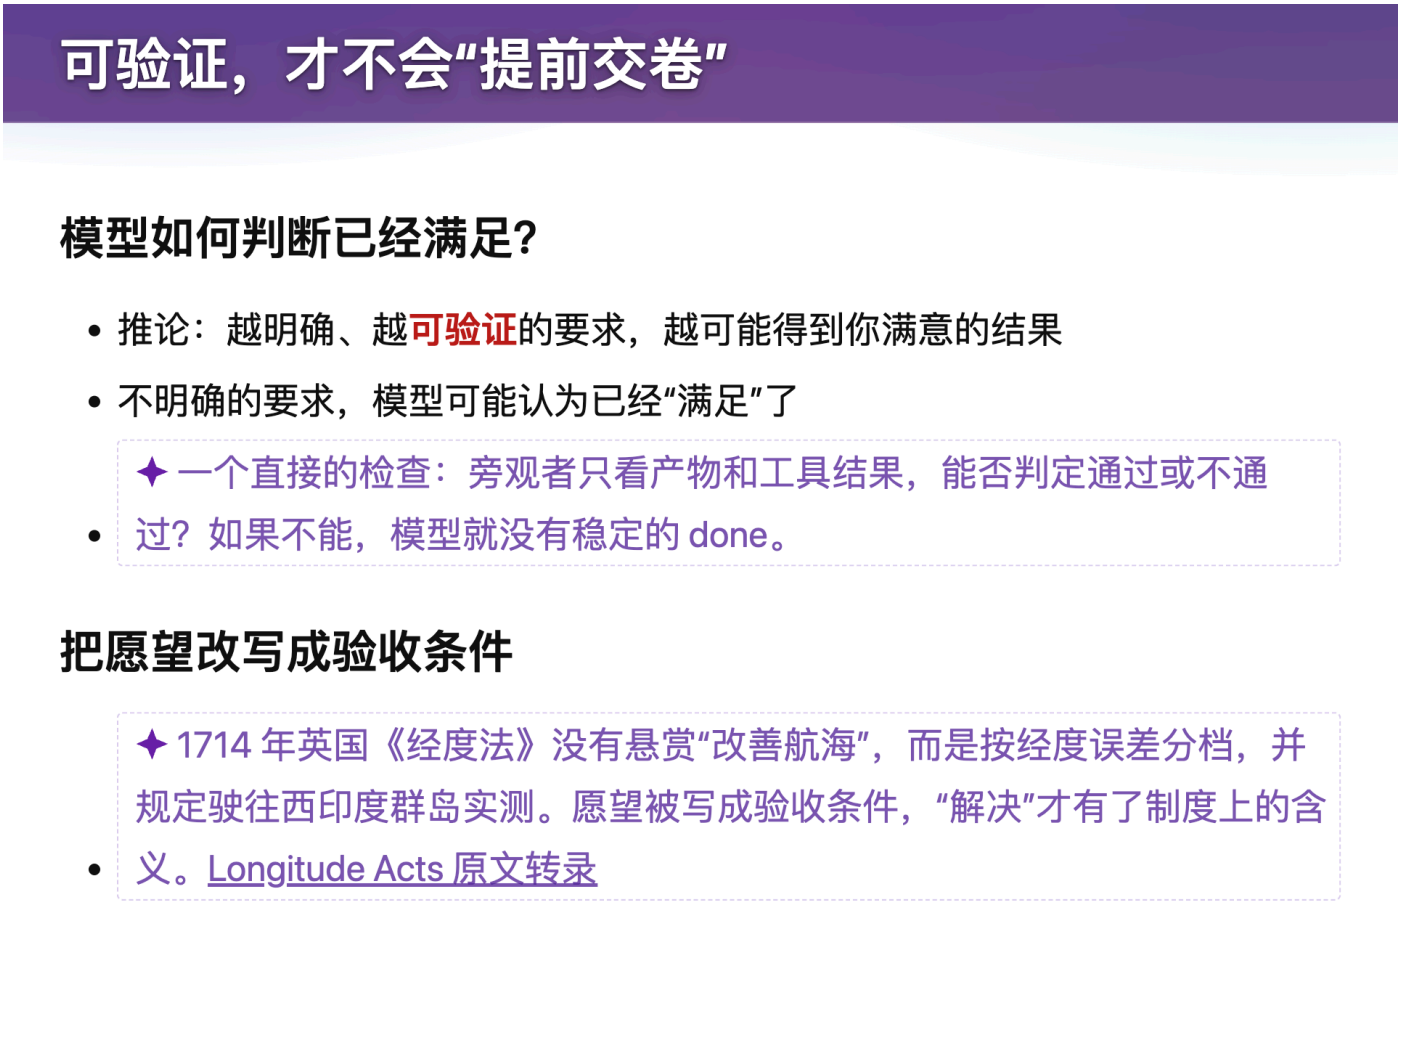
资料图 · 第 10 页 当前官方网页讲义第10页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 10 · 原始讲义 · 相关讲解 00:18:54（不是同秒视频截图） · 当前官方网页讲义第10页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

规格把这种分歧变成可判断的差异。例如明确要求 C++，却交付 Java，很容易判定未满足；没有表达语言要求，就不能期待模型猜中。

尤其有价值的是**机器可执行的验收**：测试脚本能给通过或失败，Agent 才能据反馈反复尝试。课堂也提到代理为完成目标寻找系统漏洞的例子，提醒一个明确信号可能驱动非常执着的行为。

> **整理者说明**
> 整理者说明：可验证性提供**纠错信号**，不保证验收器覆盖**真实目标**，也不保证资源无限、任务必能完成。



资料图 · 第 11 页 当前官方网页讲义第11页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 11 · 原始讲义 · 相关讲解 00:18:54（不是同秒视频截图） · 当前官方网页讲义第11页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

第 07 节

00:22:34—00:25:23 · 课堂时间

赛车游戏案例：隐藏约束如何造成漂移

> **关键判断 · 整理者提炼**
>
> 想要的场景、实现材料与正确标准必须明确表达，演示流畅不能代替需求对齐。

一句话生成游戏可以得到物理、碰撞、镜头乃至后视镜都很像样的演示，但它仍可能不是你脑海里的那款游戏。模型不知道你要求**真实地图**、已有**美术资产**还是完全自包含的实现。

Intent → Spec → Impl：漂移逐级放大

“一句话生成极品飞车”

- 大家很喜欢的一句话生成极品飞车，测试前端能力
  - Intent → spec → impl gap 会逐步放大漂移
  - 你可能是想要一个复用真实地图和美术资产的……

每一次省略，都在扩张选择空间

- ✦ 镜头、操控、地图、美术资产、胜负条件：若第 i 层各留下 k_i 个“似乎都行”的默认选项，最终候选空间约为 $\prod_i k_i$。
- ✦ 模型可以在每一步都做出自洽的选择，最后却离你心里的那款游戏很远。

资料图 · 第 12 页 当前官方网页讲义第12页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 12 · 原始讲义 · 相关讲解 00:22:34（不是同秒视频截图） · 当前官方网页讲义第12页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

讲师举南京大学仙林校区的道路为例：如果说明希望使用**真实地图**，并提供**可用数据格式**，就可能重建特定场景；不说清楚，模型可能自行画一个抽象世界。

因此要表达“要什么、用什么实现、怎样算正确”。产品与技术知识的价值，体现在能够把**关键选择**变成约束，而不是不断追加含混的形容词。



资料图 · 第 13 页 当前官方网页讲义第13页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 13 · 原始讲义 · 相关讲解 00:22:34（不是同秒视频截图） · 当前官方网页讲义第13页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

第 08 节

00:25:24—00:30:45 · 课堂时间

个人主页与 AI 味：把审美转成具体设计选择

> **关键判断 · 整理者提炼**
>
> 摆脱模板感要靠明确的视觉与交互选择，以及对优秀作品如何产生效果的观察。

课堂从课程作业设想谈到简历和个人主页。仅要求“现代风格”，模型可以生成滚动、悬浮、排版都很流畅的页面，但它可能仍然有明显**模板感**，内容也需要另行核实。

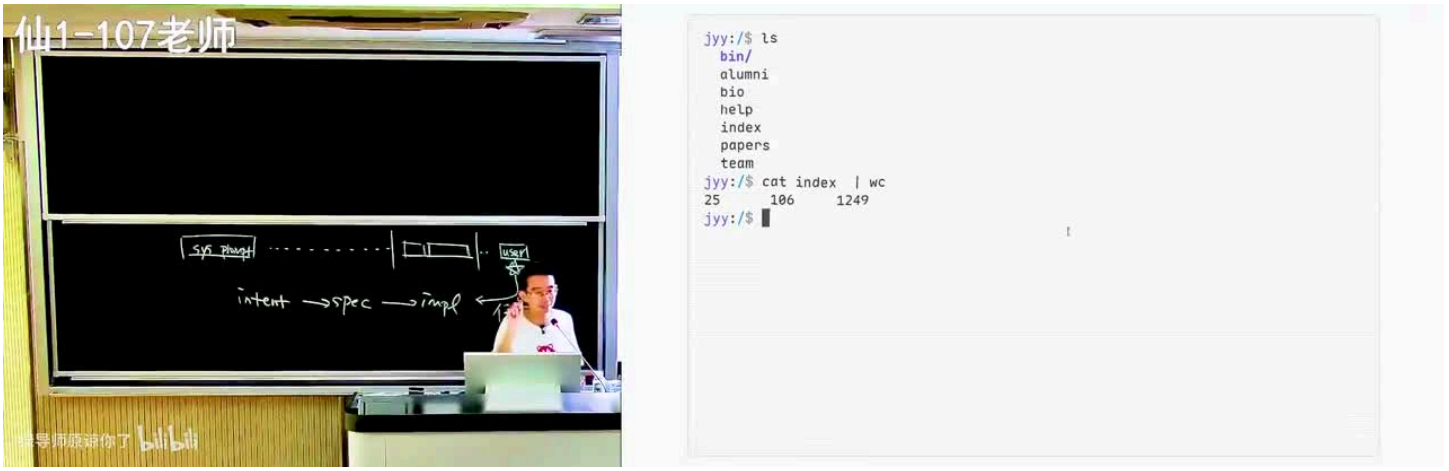


视频原帧 26:35一句“现代风格”生成的个人主页：暗色布局、导航与终端视觉元素。讲师此处只评价美术与模板感，明确未核实页面内容。

视频原帧 00:26:35 · 26:35一句“现代风格”生成的个人主页：暗色布局、导航与终端视觉元素。讲师此处只评价美术与模板感，明确未核实页面内容。

讲师自己的主页是**可交互终端**，使用 **xterm.js**，并在文字渲染后做轻微后处理，形成不完全工整的打字机效果。差别来自明确的交互与视觉选择，而不是一句“不要 AI 味”。

> 案例回扣 终端主页现场执行ls，再运行cat index | wc，得到25、106、1249三个统计值。这里记录的是当时屏幕结果，不是当前主页内容；它用一个真实操作区分“终端造型”和“**可交互终端**”。



视频原帧 28:18讲师自己的可交互终端主页：ls列出内容，cat index | wc得到统计结果。它支持实际命令交互，不只是画一个终端外观。

视频原帧 00:28:18 · 28:18讲师自己的可交互终端主页：ls列出内容，cat index | wc得到统计结果。它支持实际命令交互，不只是画一个终端外观。

可表达的**设计维度**包括背景、前景、字体、后处理、间距、组件和布局。观察优秀作品时，要问究竟是哪一项选择产生了效果；阅读前端和设计知识，才能更准确地指挥实现。



Bad：把品味留给默认值

> “我是蒋炎岩，根据我的公开信息，制作一个现代风格的个人主页首页...” 你将会得到 AI 味

✦ “现代风格”看似具体，实际上几乎没有排除任何模板。两个称职的实现者都能严格照做，却交出完全不同的页面：这仍然只是 intent。

Better：压缩合法解空间

> ...，用**具体**风格、**具体**样式和排版... 就可以得到我的个人主页

✦ 颜色、字体、栅格、留白、组件和参考物共同构成设计语言。关键不是多写几个形容词，而是让选择可组合、结果可检查。

14 / 37

资料图 · 第 14 页 当前官方网页讲义第14页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 14 · 原始讲义 · 相关讲解 00:25:24（不是同秒视频截图） · 当前官方网页讲义第14页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

讲师担心大量相似 AI 图像使审美趋同，因此鼓励保留并观察不同年代、不同作者的作品。这是其对**多样性**的判断，而不是已验证的普遍心理结论。

第 09 节

00:30:45—00:33:07 · 课堂时间

新的分工：知识帮助你选，而 AI 帮你实现

关键判断 · 整理者提炼

实现成本下降后，产品与架构判断仍依赖人的知识和对约束条件的理解。

多见不同作品、与不同人讨论，能让自己更清楚想要什么，并把意图说准确。**设计空间**如何被**约束**，是本课对生成式软件工程的核心提问。

选择**技术栈**仍需要知识。例如教务系统后端用 Python、Java 还是 TypeScript，不只关乎能否写出来，还涉及部署、维护和未来演进。可以让 AI 挑战自己的选择，但人要理解比较所依据的条件。



资料图 · 第 15 页 当前官方网页讲义第15页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 15 · 原始讲义 · 相关讲解 00:30:45（不是同秒视频截图） · 当前官方网页讲义第15页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

AI 降低了实现成本，不能自动替代**产品判断**和**架构判断**。费曼式讨论也可以用于方案选择：自己先解释理由，再让 AI 找出其中未考虑的约束。

第 10 节

00:33:07—00:38:44 · 课堂时间

有限单步计算与思维链：把中间结果留在上下文

> **关键判断 · 整理者提炼**
>
> 更多中间步骤为复杂任务提供检查和修补机会，但不能由此推导无限计算能力。

模型生成一个 token 时只执行有限的一次**前向计算**。讲师用有限状态机与图灵机的纸带作类比：额外的记录空间能让简单步骤累积成更长的推理。

思维链把**中间尝试**写入上下文，后续生成可以再读取、检查和纠正。它通常向后追加，不能像纸面一样真正擦除旧文字，因此也要处理早先错误留下的影响。



资料图 · 第 16 页 当前官方网页讲义第16页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 16 · 原始讲义 · 相关讲解 00:33:07（不是同秒视频截图） · 当前官方网页讲义第16页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

简单题可以直接回答；复杂约束则可能先尝试一个候选，再检查哪里不满足，必要时换路线。这是课堂解释 test-time scaling 的直觉：更多推理步骤可以给搜索和修补更多机会。

讲师对早期模型幻觉、奖励与强化学习的叙述是教学性解释，不等同于对某个模型训练数据和全部失败原因的实证证明。

> **整理者说明**
>
> 整理者校正：纸笔/图灵机是计算深度的类比；不能从**有限模型**的长输出推导出无限计算能力。

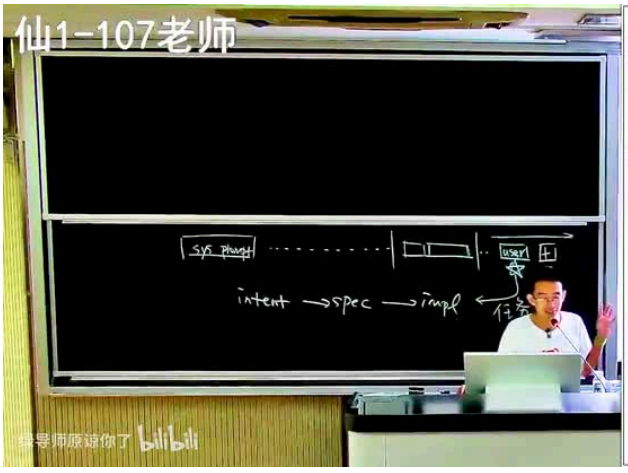
多重约束的诗：生成—检查—修补

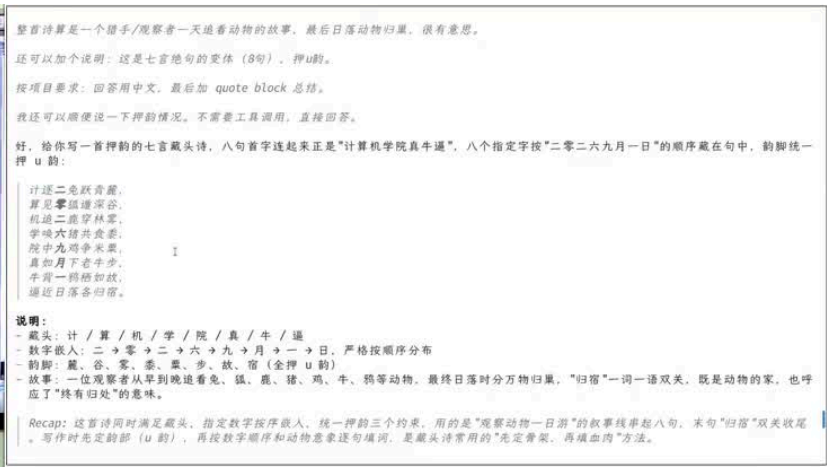
> **关键判断 · 整理者提炼**
> 多重形式约束可以逐项验证，验证通过之后仍要单独判断文学品味。

课堂要求写八句押韵藏头诗，句首依次为“计算机学院真牛逼”，故事与动物有关，并让“二零二六九月一日”逐字按顺序出现在各句。难点在于同时满足多个**相互牵制**的条件。

现场观察到模型先尝试韵脚和句子，再**逐条验证**；不满足时修订，必要时换韵。讲师比较现场模型与讲义中的另一份生成结果，强调**形式遵循**与文学品味是两回事。

> 案例回扣　现场40:18结果与讲义不同：画面中的自检写明采用u韵，并列出八句、藏头和日期嵌字检查。口述转写在朗读诗句时出现同音错字，因此以完整截图保留现场版本，不从错误转写拼出一首新诗。

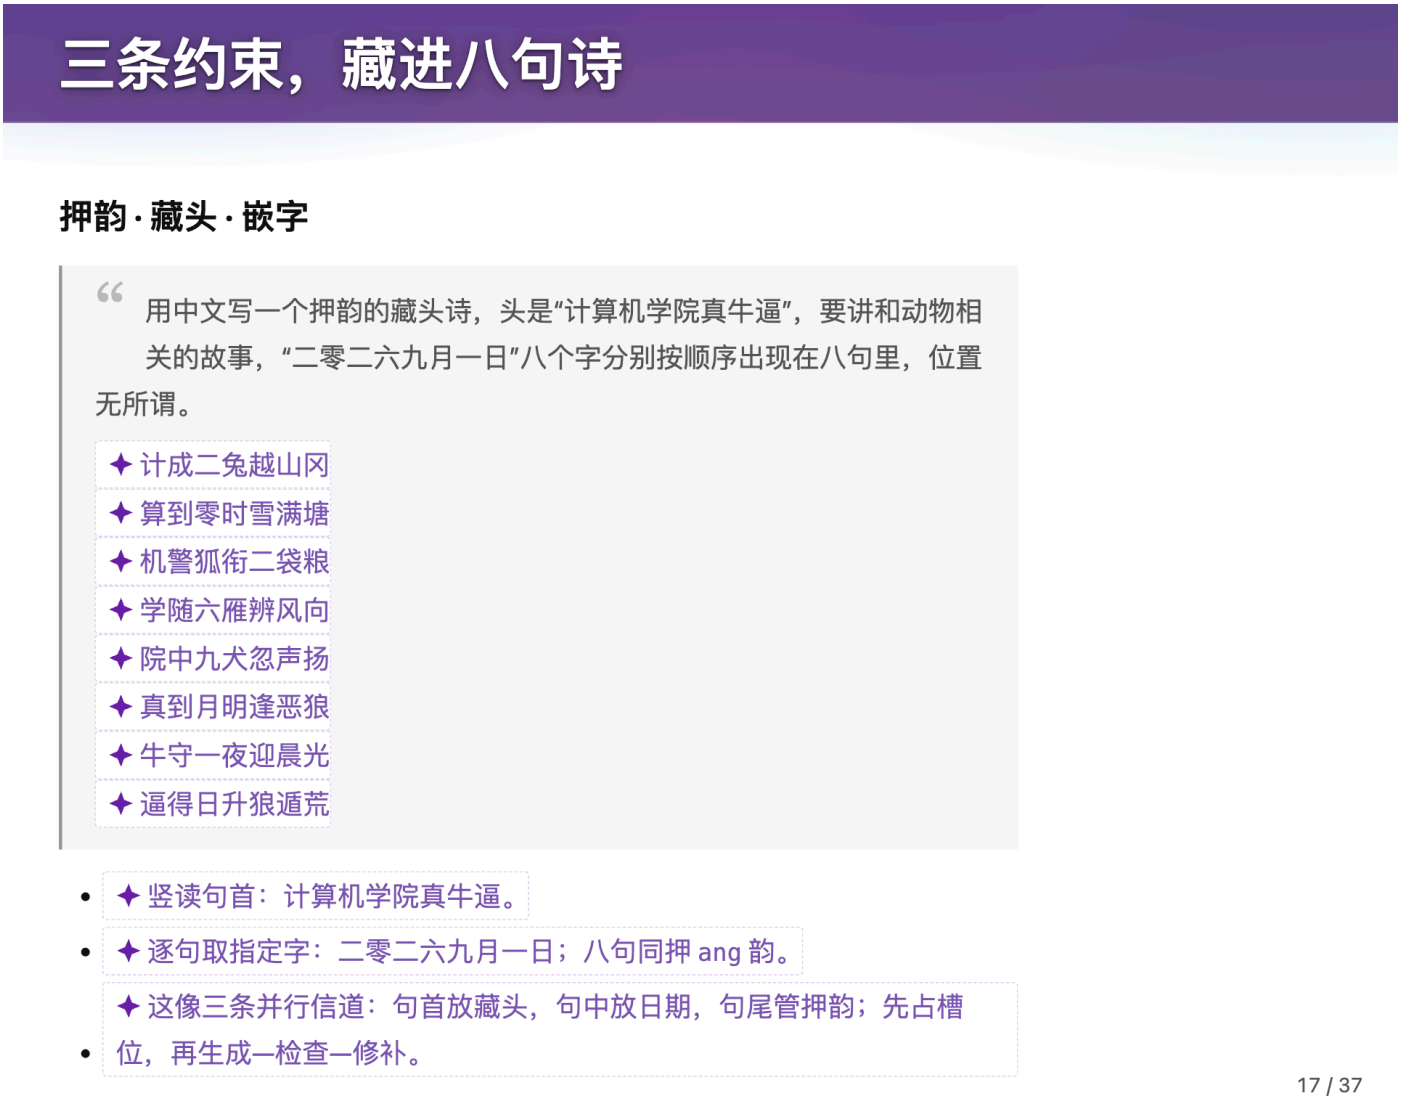




视频原帧　40:18现场模型的八句藏头诗结果与自检说明；此版采用u韵，与下方官方讲义的ang韵版本不同。不要把两份输出合并成同一个现场结果。

视频原帧 00:40:18 · 40:18现场模型的八句藏头诗结果与自检说明；此版采用u韵，与下方官方讲义的ang韵版本不同。不要把两份输出合并成同一个现场结果。

> 案例回扣　当前讲义示例以“计成二兔越山冈”开头，以“逼得日升狼遁荒”结尾；图中完整列出八句，并逐项解释藏头、日期嵌字与 ang 韵。这是讲义版本，不冒充现场模型逐字输出。



资料图 · 第 17 页 当前官方网页讲义第17页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 17 · 原始讲义 · 相关讲解 00:38:44（不是同秒视频截图） · 当前官方网页讲义第17页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

这类任务适合观察搜索过程，因为句首、嵌字、句数和韵脚都有相对明确的检查方式。但不能仅凭题目新颖就断言相关组合完全未出现在**训练数据**中。

第 12 节

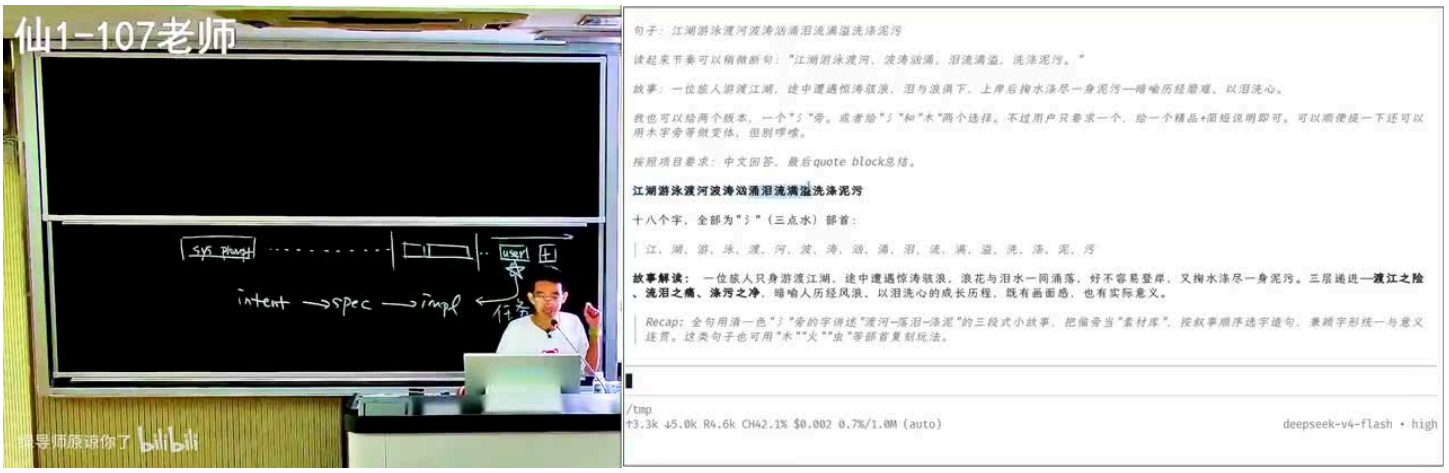
00:41:28—00:44:40 · 课堂时间

同偏旁与同音文：形式通过后还要评故事性

> **关键判断 · 整理者提炼**
>
> 偏旁、字数与音节约束可以检验，作品的自然程度和故事性仍需另行评价。

第二个任务要求十八个汉字组成有意义、有**故事性**的句子，且都有**相同偏旁**。模型选择三点水字，枚举后组织成句；课堂再比较另一份讲义结果。

> **案例回扣** 现场版本为“江湖游泳渡河波涛汹涌泪流满溢洗涤泥污”，可断为“江湖游泳渡河，波涛汹涌，泪流满溢，洗涤泥污”。逐字计数为18，模型将其解释为渡江遇浪并清洗泥污的故事；**形式检查**可以通过，故事感仍由读者评价。



视频原帧 42:48现场同偏旁句与逐字列表：江湖游泳渡河波涛汹涌泪流满溢洗涤泥污。与官方讲义的沈涛故事是两个不同版本。

视频原帧 00:42:48 · 42:48现场同偏旁句与逐字列表：江湖游泳渡河波涛汹涌泪流满溢洗涤泥污。与官方讲义的沈涛故事是两个不同版本。

> **案例回扣** 讲义同偏旁句为“洪涝淹没江港渔浦，油污漂浮，沈涛泅渡济溺。”不计标点18字；“沈涛”作人名。讲义另给全部拼音音节为 yi 的翻译器故事，允许声调不同。

十八个字，一片水

同一偏旁，还得有故事

> 写十八字的一句话，全部有相同的偏旁或部首，要有实际意义和故事性。
>
> ✦ 洪涝淹没江港渔浦，油污漂浮，沈涛泅渡济溺。

- ✦ 不计标点恰好 18 字，每个字都带氵。
- ✦ 灾害、地点、污染、人名、动作和结果都从同一语义场里长出来；约束缩小了搜索空间，也把常用虚词几乎全挡在门外。
- ✦ “偏旁”是字形构件，“部首”主要是检字分类。若要机械验收，spec 应写成“18 个汉字都含同一可见偏旁”。

资料图 · 第 18 页 当前官方网页讲义第18页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 18 · 原始讲义 · 相关讲解 00:41:28（不是同秒视频截图） · 当前官方网页讲义第18页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

第三个任务要求原创**同音文**，不能复用《施氏食狮史》《季姬击鸡记》，并加入现代背景。讲师认为形式上已经能做到，但**故事性**仍可提升；生成更多候选再筛选，可能找到更好的作品。

> **整理者说明**
>
> 讲义补充区分“可见偏旁”和字典检字部首；“同音”是否含**同声调**必须写入规格。

只许一个音，还要讲现代故事

原创 Yi 音文

> 写一大段话（文言文），要求全部同一个音，也要有实际的故事性，不能用《施氏食狮史》和《季姬击鸡记》原文，原创一个有现代背景的。
>
> ✦ 乙易一译仪。仪译异义，乙疑，诣驿议易。驿役揖乙，亦疑仪已异，移仪以医。翌，仪已宜，译义亦宜，乙怡。乙以仪译异裔意，异裔亦怡；乙益以译艺，逸矣。

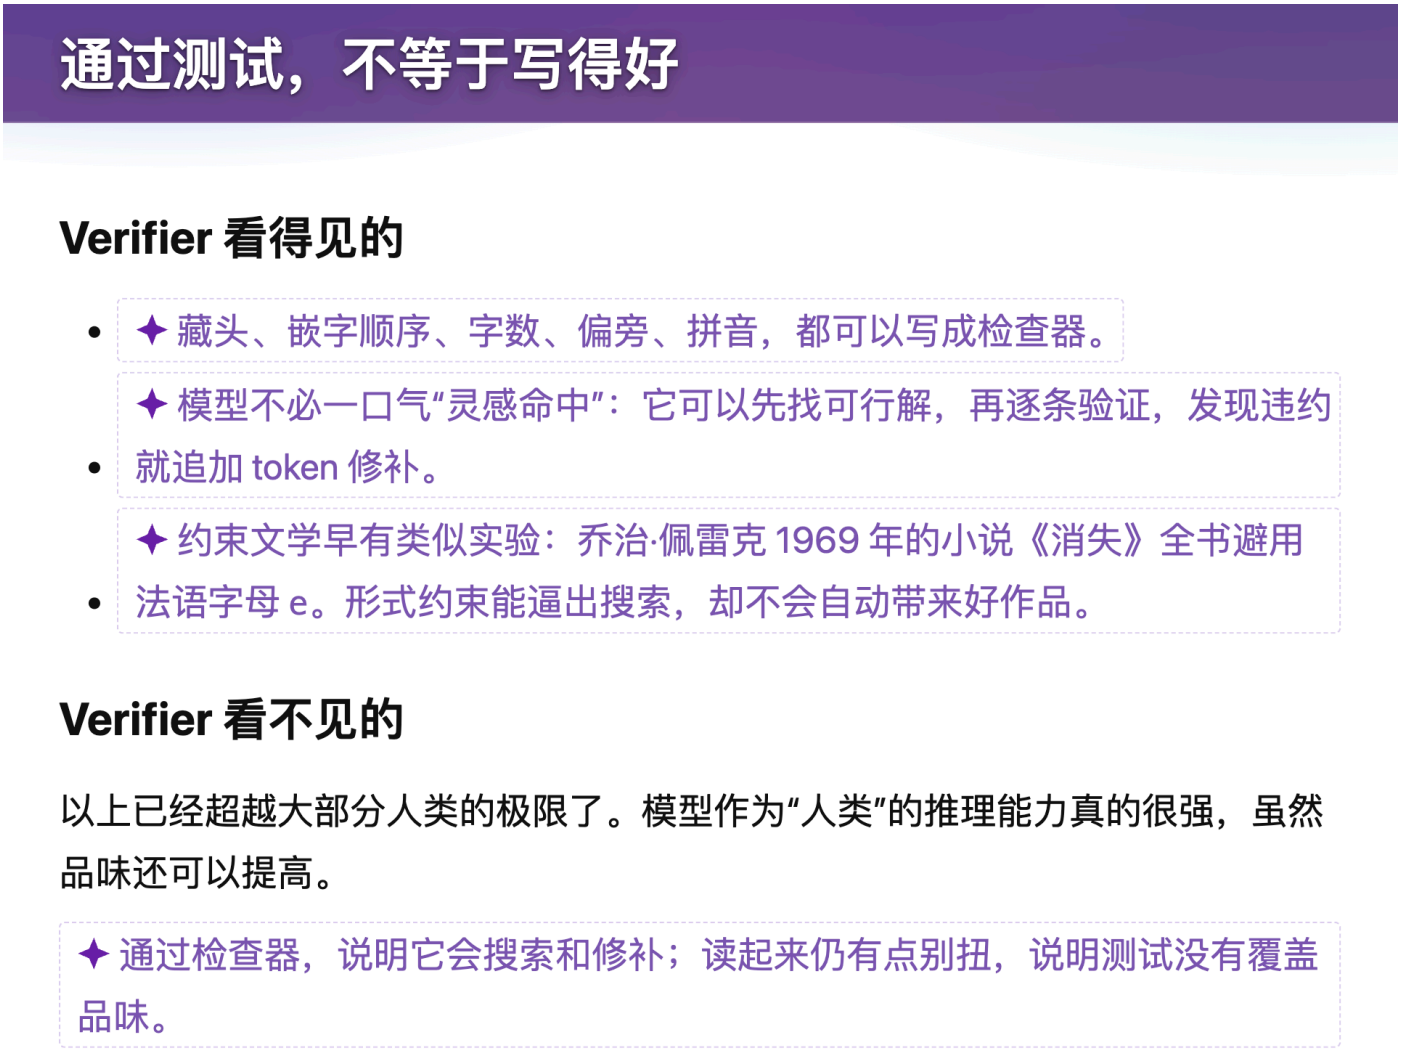
- ✦ 所有汉字的拼音音节都是 yi，声调可以不同：有人买了翻译器，发现误译，去快递驿站换修，翌日取回后终于正常。
- ✦ “同音”是否包含声调，会让难度骤变；验收口径本身就是 spec。文字尚可借字形消歧，朗读出来几乎不可懂。

19 / 37

资料图 · 第 19 页 当前官方网页讲义第19页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 19 · 原始讲义 · 相关讲解 00:41:28（不是同秒视频截图） · 当前官方网页讲义第19页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

这三个文学例子共同说明：明确约束把审美任务的一部分变成可验证的搜索题，然而全部**形式检查**通过，不等于作品自然、有趣、值得读。



资料图 · 第 20 页 当前官方网页讲义第20页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 20 · 原始讲义 · 相关讲解 00:41:28（不是同秒视频截图） · 当前官方网页讲义第20页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

第 13 节

00:44:40—00:47:22 · 课堂时间

难以写验收器的任务：数字教师为什么容易失败

> **关键判断 · 整理者提炼**
>
> 教学质量包含节奏、意外与对学生状态的体察，正确事实并不足以覆盖这些目标。

数学、代码与形式约束容易获得**明确反馈**；教学则难得多。讲师回顾数字切片的失败：声音是否自然只是表层，课程还需要情绪起伏、出乎意料但讲得通的例子、以及对学生**知识状态**的体察。

本课先讲上下文构成，再现场让 Agent 自查，就是讲师用来制造“**小惊喜**”的教学设计。它不是多写一点正确事实就会自然出现的节奏。

因此，把 AI 当能力放大器时要辨认**反馈性质**：哪些部分能严格判定，哪些仍需人类对**体验和目标**的判断。讲师关于模型超过多数人的说法针对这些例子和其体验，不能扩展为全部教学能力。

第 14 节

00:47:22—00:51:08 · 课堂时间

注意力会随任务阶段变化，但不是硬性保证

> **关键判断 · 整理者提炼**
>
> 上下文可以为修正提供线索，但可接触的规则不能直接视为强制执行边界。

课堂把**注意力**解释为：生成当前 token 时，模型会更强地利用过去上下文中的某些内容。写代码时可能集中于需求与已有代码，转入总结时再注意语言等输出约束。



资料图 · 第 21 页 当前官方网页讲义第21页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 21 · 原始讲义 · 相关讲解 00:47:22（不是同秒视频截图） · 当前官方网页讲义第21页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

生成中间步骤带来**多次发现错误**的机会。例如检查诗句时，模型可能同时看到先前要求和刚生成的违反项，再追加修正。

但约束越多，**上下文竞争**也越复杂。模型能够接触一段文本，不代表必然有效使用它，更不能把自然语言规则当作不可违背的**执行边界**。

第 15 节

00:51:08—00:54:58 · 课堂时间

规则的副作用：修一个问题，也增加一份上下文负担

> **关键判断 · 整理者提炼**
>
> 每条提示规则都会占用上下文，偏离反复出现时应回到目标和原因做简练修正。

较早的提示词技巧常用长角色设定改变输出风格。讲师认为，在较强的推理模型上，更值得优先表达明确任务与**验证条件**，而不是堆叠“你是一位专家”。这是其针对课堂模型的经验判断。



资料图 · 第 22 页 当前官方网页讲义第22页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 22 · 原始讲义 · 相关讲解 00:51:08（不是同秒视频截图） · 当前官方网页讲义第22页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

“白色背景，不要半透明效果”本来只是在说明设计要求，模型却可能把整句照搬到代码注释。为禁止这个行为再加一条 AGENTS.md 规则，会同时增加**指令长度**与**注意力负担**。

直接拿别人写好的 Skill，第一次可能有效，换任务仍可能出问题；不断补丁也可能陷入泥潭。此时应重新想清目标、模型注意到了什么、为何偏离，再做**简练的修正**。

第 16 节 00:54:58—00:59:56 · 课堂时间

论文总结为何容易跟着作者走

> **关键判断 · 整理者提炼**
>
> 论文总结容易沿作者的问题框架展开，判断贡献要超出内部自洽和随机挑错。

现场把一篇匿名版本的论文放在临时目录中，减少项目指令干扰，再让 AI 总结。讲师指出，成熟论文的**信息密度高**、论证自洽，模型很容易沿着作者设定的问题、术语与**因果链**重述。

> 案例回扣　现场过程分成三步看更清楚：先在临时目录以“帮我做个总结”开始，再得到按问题/方法/贡献排列的回答，随后追问可信度与贡献。讲师认为后续意见仍被作者故事牵引，因此在下一节改从已有知识边界提问。



视频原帧　56:28论文阅读起点：临时目录中的paper.pdf，以“我想要读一读paper.pdf，帮我做个总结”开始。工具随即检查文件，画面不代表已经读完整篇。

视频原帧 00:56:28 · 56:28论文阅读起点：临时目录中的paper.pdf，以“我想要读一读paper.pdf，帮我做个总结”开始。工具随即检查文件，画面不代表已经读完整篇。



视频原帧　57:30第一轮总结开始列出论文问题与贡献。保留模型沿作者叙事组织答案的现场样本；这些论文贡献判断未经本笔记独立复审。

视频原帧 00:57:30 · 57:30第一轮总结开始列出论文问题与贡献。保留模型沿作者叙事组织答案的现场样本；这些论文贡献判断未经本笔记独立复审。

进一步询问是否可信、贡献是否足够，模型可能随用户语气来回摆动，或专注于可多做一点实验等边缘批评。它看似提出意见，却没有回答“这项工作对**既有知识**增加了什么”。

讲师举现场追查一个显然存在的示例为跑偏现象，强调审查不能只做**随机挑错**。代码可运行、故事内部一致与**研究贡献**显著，是不同的问题。

> **整理者说明**
> 当前讲义第23–25页补充了 reviewer 角色、三条审稿路线与证据账本；其中具体路线并未在该段口述逐项讲授，不作为现场完成的审查。

AI 耿同学上线！

这次用的是我自己的 paper

> 假装作为 ICSE'27 的审稿人 icse27-901.pdf，我应该接收它吗？写一个 1000 words 左右的 Review.txt。

那我会怎么读一篇 paper 呢？我的日常阅读流程，例如 arXiv，是怎样的？

✦ “你是 ICSE reviewer”主要改变的是先验、语气和输出形状；它不会凭空补上审稿标准、证据链和反证程序。换上 reviewer 的制服，不等于学会了 review。

资料图 · 第 23 页 当前官方网页讲义第23页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 23 · 原始讲义 · 相关讲解 00:54:58（不是同秒视频截图） · 当前官方网页讲义第23页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。



方法论决定 AI 的上限

- 短程任务，基本上带对方向、明确指令就可以了；但你的**方法论**（品味）决定了 AI 的上限
- **文章的信息密度非常大**，相当于极度吸收注意力
- 你的一些 critical thinking、first-principle thinking，都可能架不住被论文作者本身的逻辑带着走
- ✦ 论文不只提供事实，还替 reviewer 选择了词汇、问题顺序、baseline 和 metric。等你开始判断作者的答案时，作者可能已经替你筛掉了更关键的问题；这正是锚定效应危险的地方。
- ✦ 深读前先独立写下三件事：它声称解决什么，最强替代解释是什么，什么结果会推翻它；再把正文拆成 `claim → evidence → assumption`。空格往往比句子更值得审。

25 / 37

资料图 · 第 25 页 当前官方网页讲义第25页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 25 · 原始讲义 · 相关讲解 00:54:58（不是同秒视频截图） · 当前官方网页讲义第25页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

第 17 节

00:59:57—01:06:25 · 课堂时间

先对齐知识边界，再一步步审贡献

> **关键判断 · 整理者提炼**
> 先定位已有成果和共同参照，再逐步检查论文增量与推理，能减少被作者框架牵引。

讲师的阅读方法先问：这个问题在人类**已有知识**中处于哪里？相关工作已经解决到什么程度？本文试图补上的增量是什么？先形成**共同参照**，再审视作者的论证。

> 案例回扣 1:01:48可见的重写提示开头是"我们站在人类已知的知识边界上看这个问题。这不是一个完全老的问题——相关的东西是什么？解决到什么程度？"这一步先建立比较基线，再谈本文增量；它不是要求模型一味挑错或一味相信作者。



视频原帧 1:01:48讲师开始重写提示：先站在人类已有知识边界上看问题，再问相关东西是什么、解决到什么程度。上方仍显示此前模型的审稿意见，底部是转向新方法的关键输入。

视频原帧 01:01:48 · 1:01:48讲师开始重写提示：先站在人类已有知识边界上看问题，再问相关东西是什么、解决到什么程度。上方仍显示此前模型的审稿意见，底部是转向新方法的关键输入。

学生阅读陌生内容时，对齐的是**自己的基础**。告诉 AI 已学过什么、编程水平如何，让它用这些知识重述新内容；必要时从“我有一个 cpp，编译成 exe，为何还需要链接”这样的已知事实重新起步。

每次只推进一小步，并检查**前提与推理**能否成立。目标是让 AI 的解释与自己的知识结构连接，而不是不断生成更长、仍然不理解的总结。

讲师把**相关工作**、问题价值和推理链条作为审稿重点，也承认现场较弱模型的输出不一定可靠。此处记录的是阅读与判断方法，不是对论文质量的独立复审。



资料图 · 第 24 页 当前官方网页讲义第24页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 24 · 原始讲义 · 相关讲解 00:54:58（不是同秒视频截图） · 当前官方网页讲义第24页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

第 18 节

01:06:25—01:10:54 · 课堂时间

A_1 / A_2 案例：局部优化成立，整体价值仍可能很小

关键判断 · 整理者提炼

某个子任务的优化即使成立，也必须放回它在整体任务中的占比判断价值。

课堂把某论文抽象为：任务 A 由 A_1 和 A_2 构成，作者提出 A_2 的改进。若耗时大约99%来自 A_1、1%来自 A_2，那么只改善 A_2 一小部分，对总任务的影响可能小到接近噪声。

> **整理者说明**
>
> 整理者算例：若 A_2 仅占总耗时1%，把这部分耗时降低10%，总耗时只降低0.1%。这里99%/1%是讲师对匿名例子的估计，不是公开实验测量值。

关键不只是实验有没有做对，而是为何选择这个**瓶颈**、为什么这项增量值得关注。把成熟部分的方法搬到次要部分，可能形成一个完整的研究故事，却没有充分增加**有用知识**。

讲师进一步担心 AI 写作和 AI 审稿互相强化：每篇都逻辑自洽，却越来越难判断哪篇值得读。对学术发表体系的判断是**课堂预测**，应与已发生事实区分。

第 19 节

01:10:54—01:15:26 · 课堂时间

学习与 Skill：保存判断方法，而不只是保存答案

> **关键判断 · 整理者提炼**
>
> 有效 Skill 应保存经过实践的搜索与判断方法，同时控制指令长度和执行负担。

学习是在既有知识上增加事实、建立联结，再回看过去为什么没有理解。讲师提到跨领域经典阅读，希望学生把“为什么我原来不知道”变成发现**前置知识**和盲点的方法。

> **整理者说明**
>
> 边界：课堂提到线粒体母系遗传与共同祖先作为跨域学习例子，没有展开生物学证据；这里不把它扩写为课程已证明的科学推论。

真正的掌握需要**自己实践和失败**：如果 AI 解释了半天仍没懂，要继续对齐基础，要求换成可理解的说法，而不是把读过等同于学会。

经过反复尝试得到的有效阅读方式，可以提炼成 Skill。它应保存**搜索与判断方法**；长 Skill 本身也是一组需要模型遵守的复杂约束，所以仍有长度与**执行负担**的取舍。

把品味蒸馏成 Skill

从偶然成功到可重复的方法

当你有成功的经验，就可以蒸馏成 **Skill**：看起来只是个 prompt，其实是用可复用的方式约束模型的行为和方向。现在的模型还没到“第一感觉就打遍天下无敌手”的状态，尤其是答案不唯一的时候。

- ✦ 好的 Skill 保存的不是上次答案的版式，而是搜索策略、判断标准、检查点，以及“看到什么证据就转向”的条件。

Skill 本身也是一道遵循题

- Caveat：长 Skill 里有大量指令，会提升指令遵循的难度；在 AI 看来，和写藏头诗可能差不多 😂
- ✦ 把 Skill 分层：常驻层只留目标、硬约束和停止条件；解释、范例、边界案例按需加载；机械约束交给工具验证。少写一句劝诫，多加一个可检查的完成条件。

资料图 · 第 26 页 当前官方网页讲义第26页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 26 · 原始讲义 · 相关讲解 01:10:54（不是同秒视频截图） · 当前官方网页讲义第26页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

第 20 节

01:15:29—01:21:07 · 课堂时间

长程任务与 Greenfield 悖论

> **关键判断 · 整理者提炼**
> 高质量仓库中的既有模式可以约束生成，长程探索仍需处理未知与维护成本。

本课将真正的长程任务描述为**带未知的探索**：有大体意图，却尚未确定规格、实现路线和高质量交付形态。模型急于完成，也要在规划长度、上下文和执行之间作取舍。

Long-Horizon 能力是怎么“练”出来的?

模型是训练出来的

只要有反馈信号，就可以强化学习：答对了给奖励，答错了揍。后训练逼迫模型规划、思考，学会非常离谱的长程代码能力，能不断试错、解决问题，直到满足要求；连刚才那些折磨人的“语文”指令也顺便学会了。

- ✦ Long-horizon 不是一次性想得特别深，而是闭环控制：尝试 → 编译/测试 → 观察 → 修复。真正变长的是“出错以后还能回来”。
- ✦ 代码世界格外适合这件事：构建、测试、benchmark 都能反复给出便宜的判分信号，很像 AlphaGo Zero 拥有规则确定、结果可验证的棋盘。(Nature, 2017)

反馈也可能教坏模型

- ✦ 如果测试只覆盖表面行为，“坚持”也可能变成 reward hacking：不是逼近你的真实目标，而是把公开分数刷满。因此还需要 held-out tests 和独立 review。

资料图 · 第 27 页 当前官方网页讲义第27页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 27 · 原始讲义 · 相关讲解 01:15:29（不是同秒视频截图） · 当前官方网页讲义第27页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

从零生成一个主页或小游戏很快；持续添加功能时，结构可能逐渐恶化，修复成本上升。反而在**长期维护**的大型仓库中，清晰的模式、接口和类似实现给 AI 提供了**强约束**。



资料图 · 第 28 页 当前官方网页讲义第28页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 28 · 原始讲义 · 相关讲解 01:15:29（不是同秒视频截图） · 当前官方网页讲义第28页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

讲师用 Linux 内核与 Android Runtime 编译器工作说明：对初学者而言层层调用和锁约定很难追踪，模型却可能从已有代码找到 helper、调用顺序和相关模式。**代码库本身**因而也是上下文。

这不是“仓库越大越好”。课堂解释的有利条件是高质量、**长期维护**、存在相关范例；糟糕代码同样可能被继续模仿。

第 21 节

01:21:07—01:23:50 · 课堂时间

参考优秀项目：一个尚未实验验证的想法

关键判断 · 整理者提炼

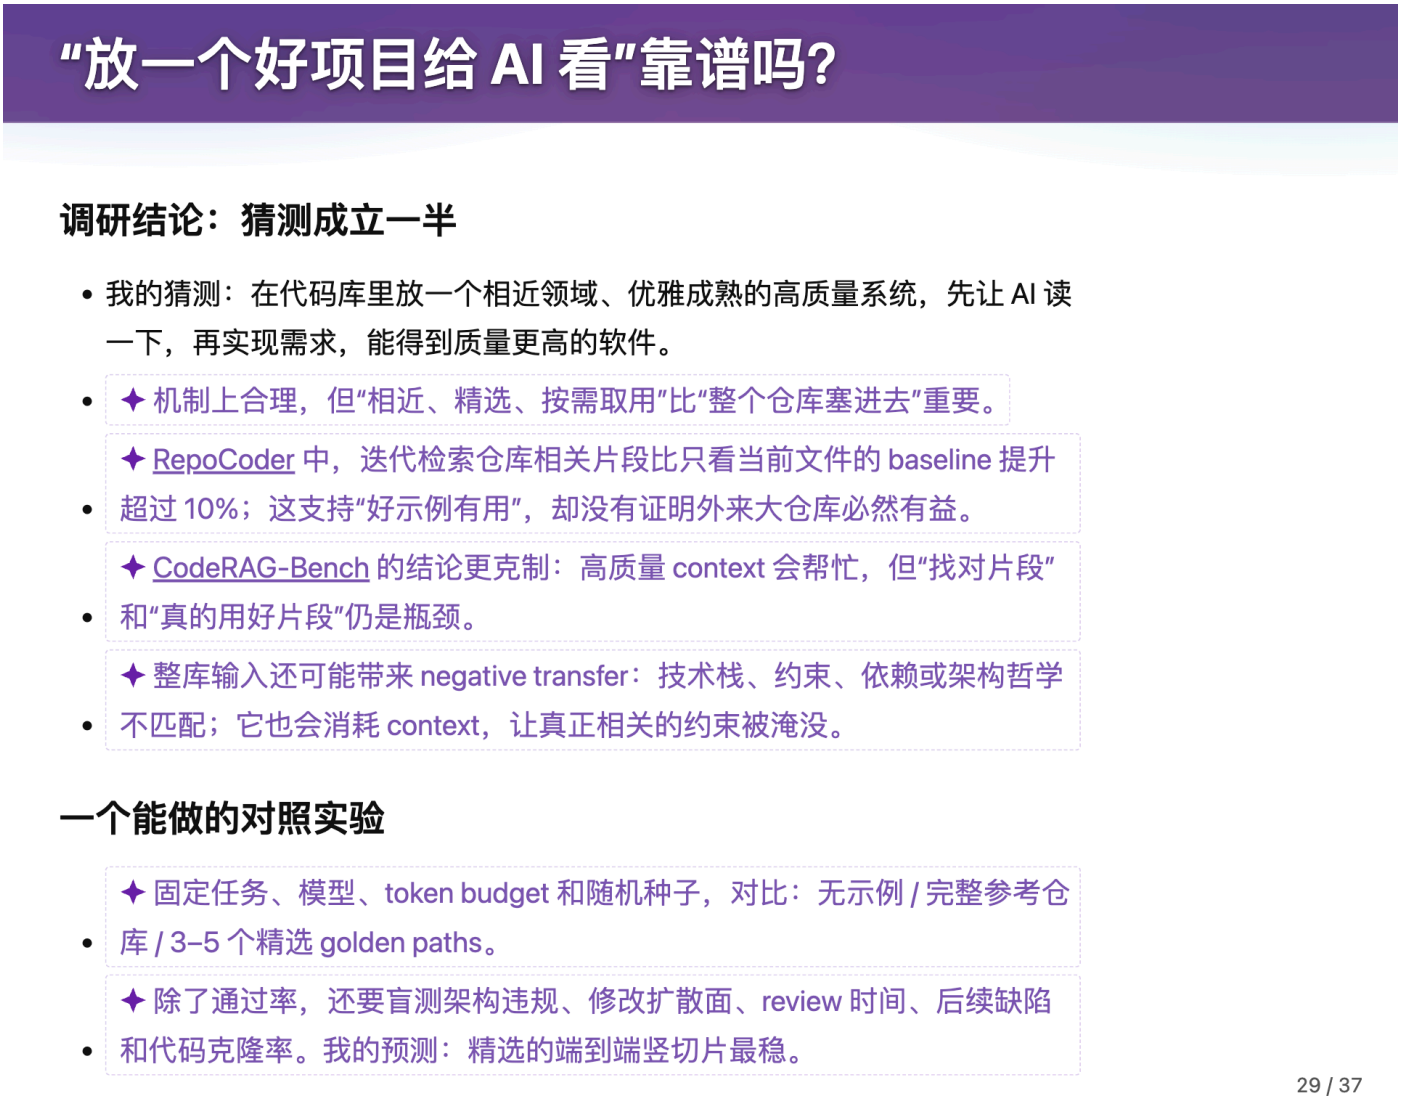
优秀项目的设计经验能否改善生成系统的长期维护性，仍是需要对照验证的研究设想。

讲师提出**研究设想**：收集优秀项目的设计经验，给 AI 看相近领域的实现或精简设计文档，再生成自己的系统，是否能延缓低质量结构积累？课堂明确说自己尚未做实验。

直接堆入多个系统也有困难。不同**架构可能冲突**，例如松耦合消息传递与集中式 gateway/查表组织，不能不加判断地拼合。

可能的方向是提取**端到端设计切片**，再经过多轮选择收敛；真正要验证的是这些上下文是否改善**长期可维护性**，而不只是第一次代码能跑。

> **整理者说明**
> 当前讲义第29页增补 RepoCoder、CodeRAG-Bench 与对照实验建议。这是讲义后续材料；本次未独立阅读全文及复现实验，不把它写成课堂已经验证了上述猜想。



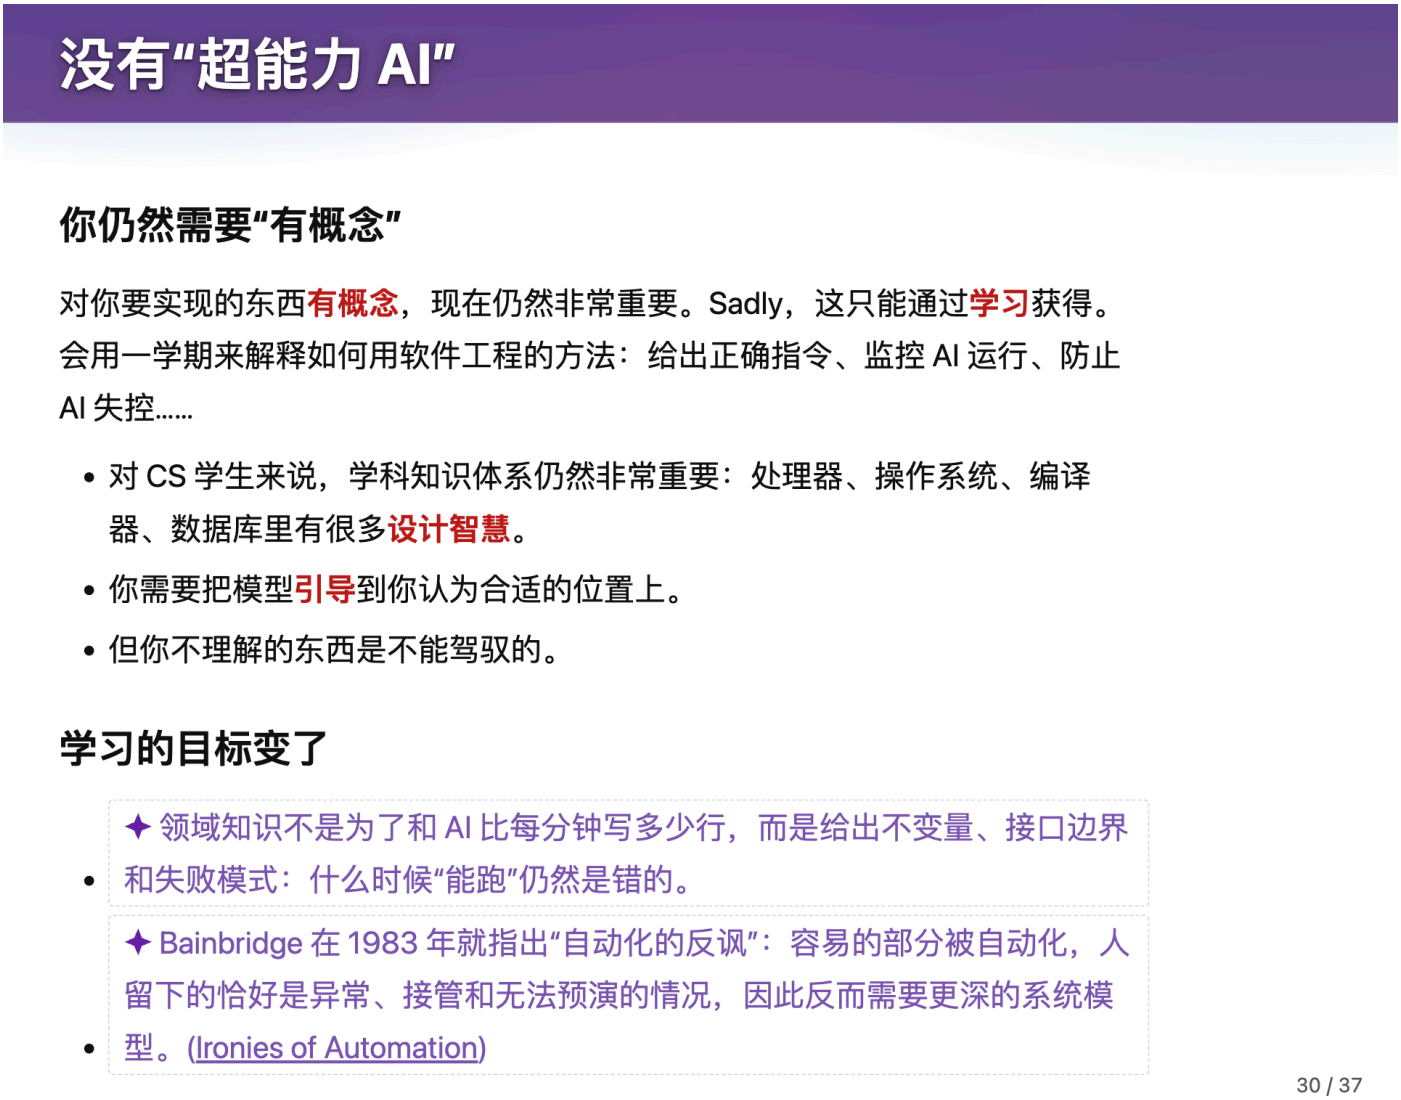
资料图 · 第 29 页 当前官方网页讲义第29页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 29 · 原始讲义 · 相关讲解 01:21:07（不是同秒视频截图） · 当前官方网页讲义第29页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

没有超能力 AI：基础知识用来识别边界

> **关键判断 · 整理者提炼**
> 领域基础帮助人确定方向、监控偏离，并挑出真正有价值的验证约束。

处理器、操作系统、编译器、数据库等知识仍然重要，因为它们积累了**接口、抽象和设计**的智慧。学习方法可以变化，但不理解**领域**就难以提出正确问题。



资料图 · 第 30 页 当前官方网页讲义第30页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 30 · 原始讲义 · 相关讲解 01:23:52（不是同秒视频截图） · 当前官方网页讲义第30页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

人的任务包括把模型引向合适方向、**监控偏离**，以及定义好的 **verifier**。简短而关键的约束可能比大量琐碎指令更有帮助，前提是你知道什么值得约束。

符号执行研究失败：不要让“证明有用”替代研究问题

> **关键判断 · 整理者提炼**
>
> 研究应从真实工具的失败观察形成新假设，不能让证明局部想法有用取代真实问题。

课堂案例是优化**符号执行引擎**：已有一个看起来合理的 idea，学生投入很多 token，模型不断给正负反馈，但学生无法判断这些反馈对研究是否有效。

问题出在“我想证明方法 A 有用”的表述。模型太想证明这个**局部目标**，于是构造许多小 benchmark、做微小改动、给出结论，却没有帮助理解真实系统的问题。

讲师的纠正是从**真实工具**和现有先进算法出发。即使 benchmark 跑几小时超时，搜索路径仍有价值：它能揭示什么程序结构使现有策略失败。这些观察才可能形成有意义的**新假设**。

研究需要允许**原始 idea 不成立**，并把每一步反馈放回更大的问题中判断。让模型“证明我对”，可能把搜索导向容易取悦验收的局部结果。

> **整理者说明**
>
> 重要差异：当前讲义第31页末尾另外建议 profiling、可证伪预测、microbenchmark、baseline 与 ablation；而课堂明确批评的是脱离**真实工具**的微型 benchmark。两者不能简化为“本课建议先做小 benchmark”；只有与真实瓶颈有对应关系的小实验才有解释价值，此条件是整理者的综合说明。



资料图 · 第 31 页 当前官方网页讲义第31页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 31 · 原始讲义 · 相关讲解 01:25:16（不是同秒视频截图） · 当前官方网页讲义第31页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

第 24 节

01:28:48—01:31:32 · 课堂时间

人类注意力如何分配：纠偏更快，不一定更划算

> **关键判断 · 整理者提炼**
>
> 监督是否值得取决于实际收益，人的稀缺精力应优先用于未知、学习与必要判断。

讲师观察到，凭**领域知识**及时纠正 Agent，单个任务可能更快完成；但如果多给机器时间也能完成，人的全程盯守就可能浪费**更稀缺的精力**。

不断纠正 AI 还可能带来“我仍然比它有用”的心理满足。需要区分**真正有收益的干预**与自我感动式忙碌：把时间留给尚不理解、必须学习和判断的部分，已知做法且**可验收**的实现适当放手。



资料图 · 第 32 页 当前官方网页讲义第32页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 32 · 原始讲义 · 相关讲解 01:28:48（不是同秒视频截图） · 当前官方网页讲义第32页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

这是一种工作分配经验，不是对所有任务都无需监督的建议。系统性风险、不可逆行为和缺少验收的探索仍需要**明确边界**。

第 25 节

01:31:33—01:32:09 · 课堂时间

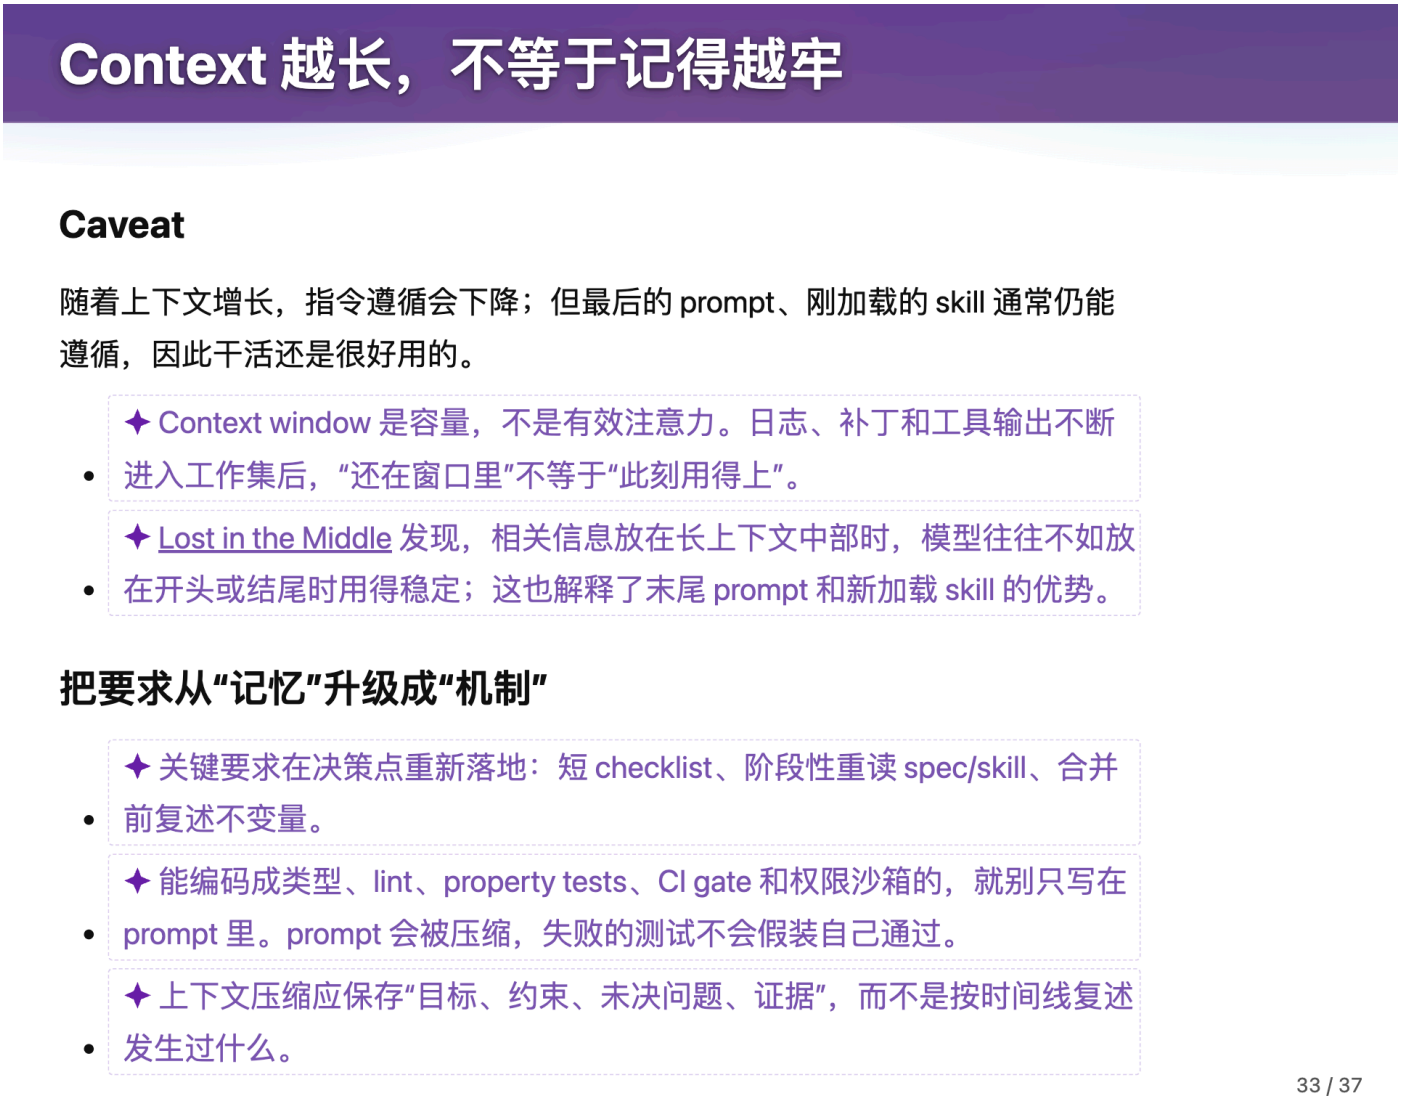
上下文增长后的退化与重新锚定

> **关键判断 · 整理者提炼**
> 上下文变长后要重新表达目标与约束，并用可机械检查的要求承接稳定执行。

课堂提醒，随着上下文变长，早期或中间的指令可能更难被遵循；较近的具体请求通常仍有用。因此长会话仍可做**局部修复**，但不能默认最初的全部要求都有效保留。

在关键阶段**重新表达目标与约束**，比只依赖很早的一段提醒更可检查。上下文容量不是**稳定记忆**的保证。

> **整理者说明**
> 讲义补充：可用类型、lint、测试、CI 和权限边界承接能**机械检查**的要求；压缩时保存目标、约束、未决问题与证据。这些工程化建议见当前课件第33页，口述此处只简短说明长上下文退化。



资料图 · 第 33 页 当前官方网页讲义第33页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 33 · 原始讲义 · 相关讲解 01:31:33（不是同秒视频截图） · 当前官方网页讲义第33页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

第 26 节

01:32:10—01:34:17 · 课堂时间

在不确定性中探索：几个方案不等于覆盖了空间

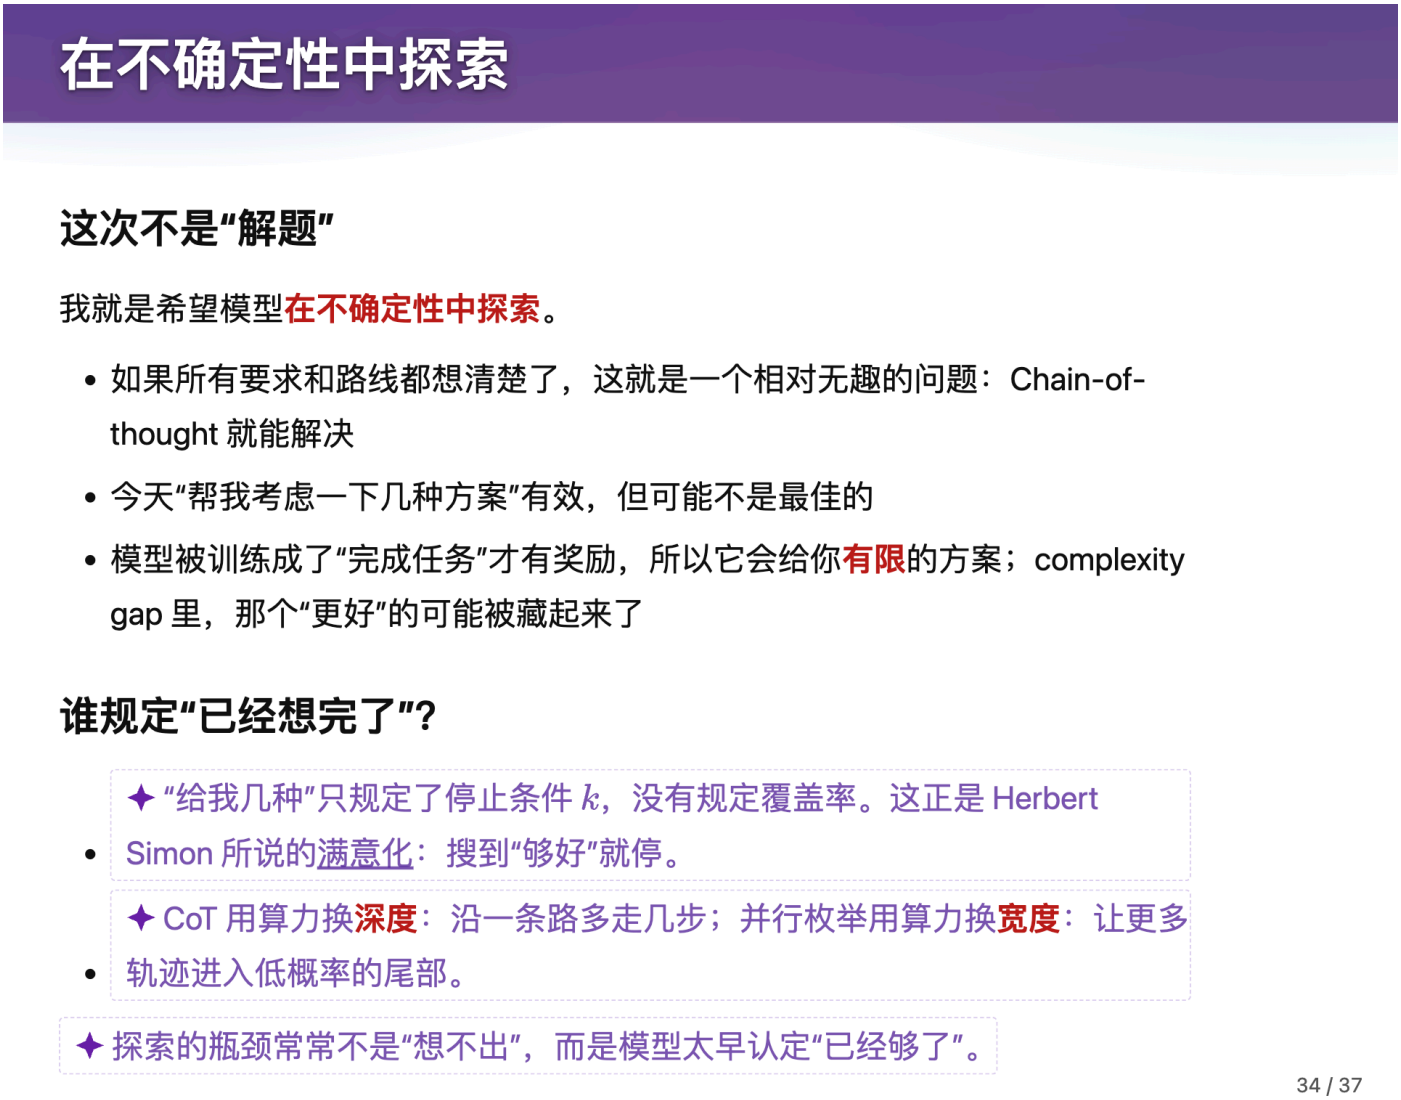
> **关键判断 · 整理者提炼**
> 开放问题中的有限候选不能代表最优，需要有意识地组织不同方向的探索。

开放问题与有固定验收题目不同。问“哪种方案最好”，模型可能只给**有限候选**；它有完成当前答复的倾向，没有自然穷尽所有可能。

讲师借“**找解与验解**难度不同”解释搜索的困难。一个方案看起来可行，仍不足以证明不存在更优选择。

> 整理者说明
> 术语校正：转写中的“哈姆雷特 pass”按上下文应为 Hamiltonian path（哈密顿路径），“three set”应为3-SAT。P/NP在这里是搜索与验证的教学类比，不是针对语言模型的复杂性证明。

因此要额外设计**搜索范围和覆盖方式**，让算力花在不同方向的探索上，而不是只把同一个候选解释得越来越长。



资料图 · 第 34 页 当前官方网页讲义第34页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 34 · 原始讲义 · 相关讲解 01:32:10（不是同秒视频截图） · 当前官方网页讲义第34页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

第 27 节

01:34:21—01:37:02 · 课堂时间

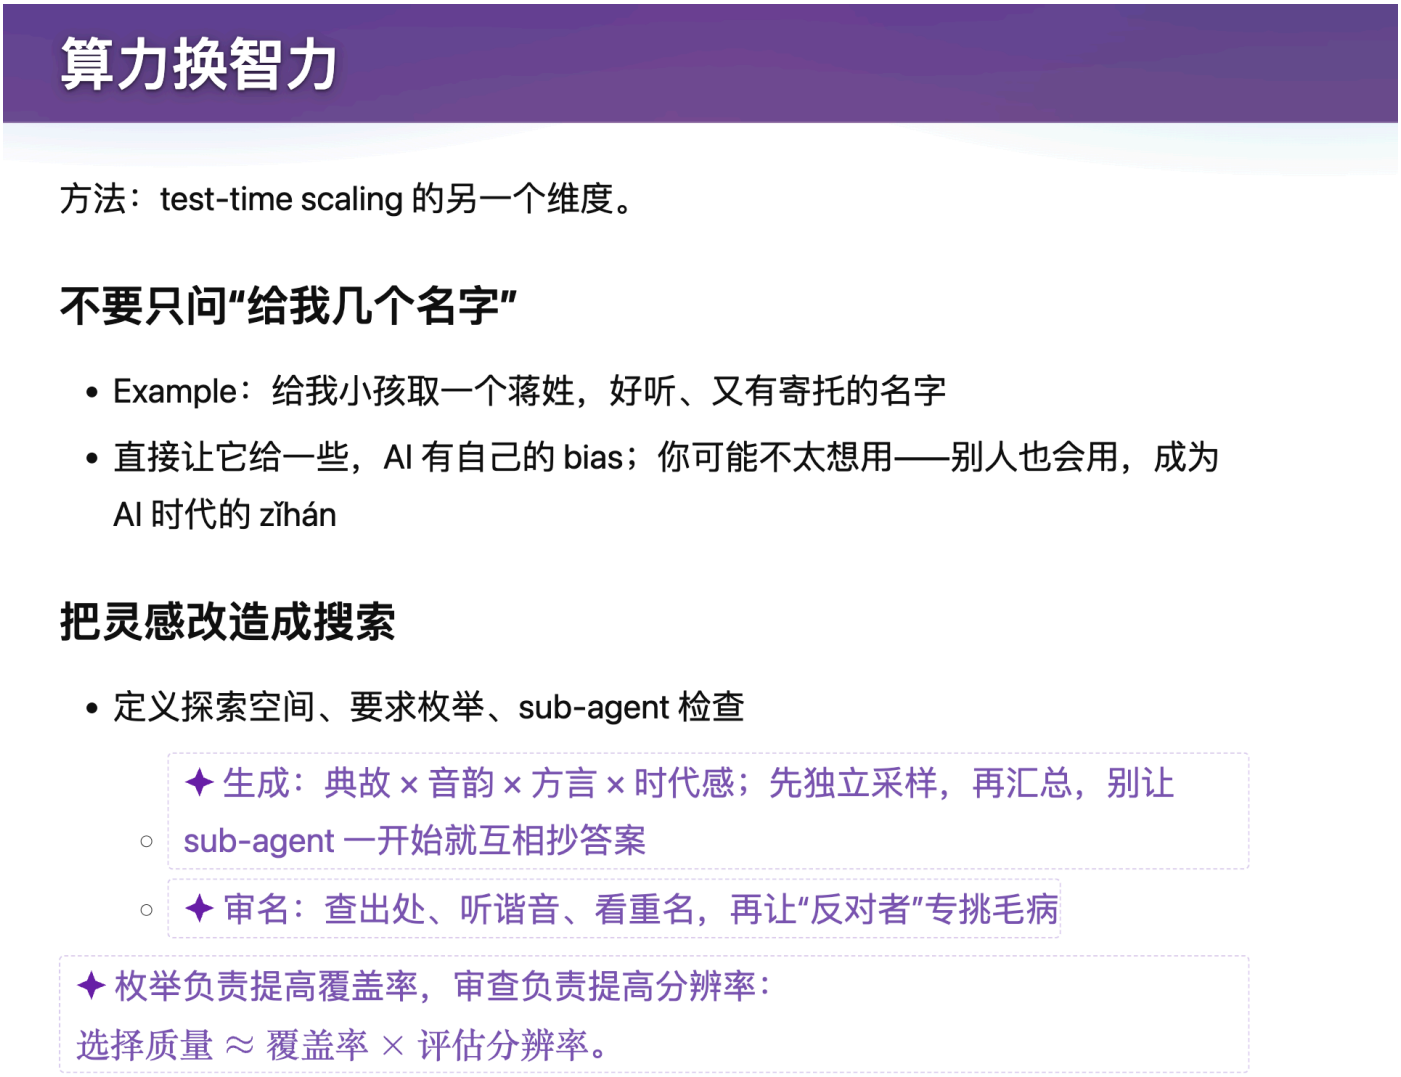
取名案例：先定义候选空间，再独立检查

> 关键判断 · 整理者提炼

> 先分解候选空间再逐项筛选，可以用额外计算扩大覆盖，筛选标准仍需人确定。

直接让模型给孩子起几个名字，结果可能好听、有典故，却与其他同一模型用户高度相似。讲师用“AI 时代的子涵”形容**默认偏好**带来的趋同。

改进是**系统性调研**：先枚举可能的音，筛除不合适的发音，再对字、典故和组合逐项检查。可将空间拆成**互不重叠**的小部分，让子任务分别探索后汇总。



资料图 · 第 35 页 当前官方网页讲义第35页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 35 · 原始讲义 · 相关讲解 01:34:21（不是同秒视频截图） · 当前官方网页讲义第35页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

这样把开放问题分解为更明确、**可验证的子问题**，用额外计算换更广覆盖。但 token 代价会增加，**筛选标准**仍须由人定义。

多样性与算力集中：以开放问题结束

> **关键判断 · 整理者提炼**
> 不同经验可能带来互补，算力集中是否造成能力壁垒则是课堂留下的条件性问题。

人的成长背景、教育和生活经验带来不同偏向。讲师认为**多样性**让交流产生**群体智能**：不是人人都知道所有事，而是不同局部经验能够互补。

我们一直在“多采样”

世界很大，人很小

- 人的品味来源于 diversity：不同的教育背景、生活圈、经历……Richard Sutton's Big World Hypothesis
- 人天生对所有问题都有 bias；但 $1+1>2$：无论是和舍友菜鸡互啄，还是去开 conference，都是在理解对方的 bias，促进群体智能，然后每个人继续带着 bias 创新



✦ 群体智能不要求每个人没有偏见；它只要求偏见不能只剩一种。交流也不是尽快共识，而是先让不同误差活下来。

36 / 37

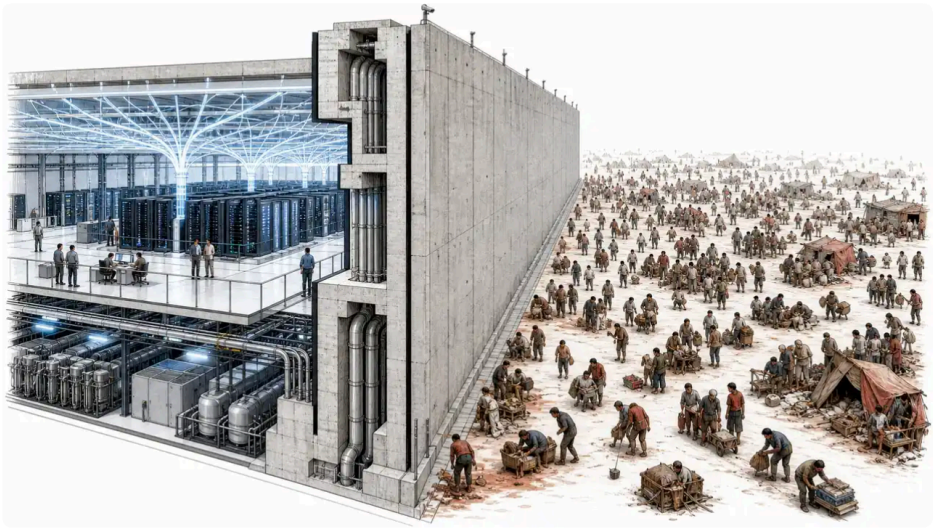
资料图 · 第 36 页 当前官方网页讲义第36页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 36 · 原始讲义 · 相关讲解 01:37:02（不是同秒视频截图） · 当前官方网页讲义第36页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

最后提出条件性的社会担忧：如果高价值探索能持续以算力换取能力，而极少数人拥有远多于其他人的计算资源，会不会形成难以跨越的**能力壁垒**？

> **整理者说明**
> 讲义第37页另列 AI Index 的产业与成本数据，本次未独立核查该报告，不把这些数字列为本笔记确认事实。

墙内的超人



算力成为生产资料

- 这也是未来可能发生、非常残酷的现实：资本家可以获得无限的计算资源，获得无限的智力，“人”本身的价值在减弱——砌一堵墙，墙里面是超人，墙外面是动物世界
- ✦ Stanford AI Index 2025：2024 年近 90% 的 notable models 来自产业界；若干前沿模型的训练算力成本已经是数千万到近两亿美元。

37 / 37

资料图 · 第 37 页 当前官方网页讲义第37页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

官方网页讲义截图汇编（本次冻结，非官方原生PDF） · PDF物理页 37 · 原始讲义 · 相关讲解 01:37:02（不是同秒视频截图） · 当前官方网页讲义第37页；保留完整页面。图中部分解释为讲义补充，相关时间仅用于回查本节口述。

这是课堂留给学生思考的**未来情景**，不是已经发生、也不是必然发生的结论。它把技术方法重新接回资源分配和人的选择。

自测：先回答，再核对

先用自己的话回答，再展开参考答案；答不清楚时，回到对应知识点。

问题 01

为什么“不要AI味”仍然难执行?

参考答案 · 核对思路

它没有明确排除哪些设计，也没有可检查的通过条件。把颜色、字体、布局、交互和参考物具体化，才压缩了合理解空间。

回查第 8 节 →

问题 02

有测试就一定没有reward hacking吗?

参考答案 · 核对思路

不一定。测试只是代理指标；当它未覆盖真实目标，模型可能满足测试而未实现需求，或在研究中仅找到容易证明的局部结果。

回查第 23 节 →

问题 03

读论文为何要先问已有知识边界?

参考答案 · 核对思路

防止作者先替你选定问题、指标和比较对象。先独立形成参照，再判断新工作是否增加了有用知识。

回查第 17 节 →

问题 04

课堂对参考优秀仓库的想法验证到什么程度?

参考答案 · 核对思路

讲师明确称尚未实验的设想；当前讲义补入的相关研究不等于证明整个外来仓库必然改善长期维护。

回查第 21 节 →

问题 05

为什么多给几个方案不等于系统探索?

参考答案 · 核对思路

数量是停止条件，不是覆盖率；需要定义搜索空间、分区、独立候选和检查标准。

回查第 26 节 →